보강데이터 조사 검증 리포트

장다예(B) 1주차 보강데이터 조사 결과 — 원본파일 재현 검증 + 실사용성 검수

검증 대상: CASRN 결측 12건 원인분석, ChemSkin DB 2.0 / XGB(Kang 2023) 보강데이터 조사 결과 · 검증 방법: 원본 xlsx/pdf/docx 파일을 직접 열어 보고된 수치·결론을 재현 · 검증일: 2026-08-13

① 1주차 필터링/CASRN 결측 확인 단계 검증

1. 검증 결과 총괄

항목	B의 보고 내용	검증 결과
CASRN 결측 건수/위치	1,799건 중 12건, MIX82/380/86/78/514/382 등 6개 Formulation	[일치] 원본 xlsx 직접 필터링 재현
ChemSkin DB2.0 규모	Table 3, 234개 참조 화학물질	[일치] 논문 abstract·본문 4곳에서 234 확인
ChemSkin DB2.0 겹침(mixture)	skin_filtered CASRN 270종과 6종만 겹침	[부분확인] PDF Table3 회전텍스트로 155/234종만 추출됨 — 전체 234종 기준 재검증 필요
XGB(Kang2023) 규모/분포	545개, CAS 500종, Cat1 160/Cat2 229/Cat3 95/NC 61	[일치] 원본 xlsx 직접 로드 재현
XGB ↔ skin_filtered 겹침	CASRN 7종 겹침, 확인 필요 전제조건 2가지 제시	[일치] 겹침 7종·등급차이 사례 3건 모두 재현됨
GHS classification(내부)	n=79, Chemical 단위, 보조피처로만 활용 가능	[일치]
CASRN 12건 내부 join 복구	"원본 파일 내부 join만으로 12건 전부 복구 가능"	[오류] 아래 2번 상세
XGB 537건 순수 추가 시뮬레이션	"단위 플래그만 추가하면 즉시 병합 가능한 수준"	[오류] 아래 2번 상세

※ 위 표의 [일치]/[오류] 판정은 CASRN 필터링 재현, PDF 텍스트 추출, xlsx 직접 로드를 통해 원본 파일에서 다시 계산한 결과이며, B가 채팅으로 공유한 수치·결론과 대조한 것이다.

2. 정정이 필요한 결론 (2건)

오류 ① — "CASRN 결측 12건, 원본 파일 내부 join만으로 전부 복구 가능"

실제 확인 결과: 결측 12건은 Record_ID가 여러 행으로 나뉘어 정보가 흩어진 문제가 아니라, "Captan-related derivatives", "Dichlorvos-related compounds", "Atrazine-related compounds" 등 미확인 잔류/분해산물 카테고리다. 데이터셋 전체(skin_irritation.xlsx, 전체 2,058행)를 뒤져봐도 이 이름을 가진 성분이 CASRN을 가진 적이 단 한 번도 없다.

즉 같은 Formulation_ID(예: MIX82)에 Captan(CASRN 133-06-2, 함량 47.5%)이라는 확인된 성분이 같이 존재하긴 하지만, 이는 "주성분"이고 "related derivatives"는 그 분해산물/불순물로 보이는 별개 행이라 서로 다른 CASRN을 가져야 하는 항목이다. 내부 join으로 메울 수 있는 결측이 아니다.

→ 결론: 외부 보강 없이는 복구 불가. 3주차 라벨링 단계에서 처리방침 결정 필요 (제외 / "unidentified residue" 플래그 부여 / 주성분 CASRN으로 대체 후 근사치 처리 중 택1).

오류 ② — "XGB 537건 순수 추가 시, 단위 플래그만 추가하면 즉시 병합 가능"

실제 확인 결과: XGB(Kang2023) 원본 파일(545행) 자체에 CASRN 중복이 88행 존재하고, 그중 43건은 서로 다른 Category로 상충된 상태로 들어있다.

예시: Geraniol(CASRN 106-24-1)이 한 행은 Cat 2, 다른 행은 Cat 3로 등재. 1,2-epoxybutane(106-88-7)은 Cat 1과 Cat 2로 상충. Methyl formate(107-31-3)은 Cat 2와 Cat 3로 상충 등.

이 상태로 겹침 7종만 제외하고 나머지 537종(고유 CASRN 기준 493종)을 그대로 합치면, 상충된 라벨이 노이즈로 섞여 들어가 B가 제시한 "Category 1: 71→227건, Category 2: 35→263건" 같은 보강 시뮬레이션 수치가 실제보다 부풀려진다.

부가로 CASRN 컬럼 자체에 엑셀 자동 날짜변환으로 깨진 값이 5건 있다 (예: Propionic acid 원래 CAS 79-09-4 → "1979-09-04 00:00:00"으로 저장됨). 문자열 그대로 매칭하면 이 5건이 전부 누락된다.

→ 결론: 병합 전 (1) CASRN 문자열 강제 캐스팅+5건 수동 복구, (2) CASRN 중복 88건 중 상충 43건 해소(다수결/최신문헌 우선 등 규칙 필요), (3) Physical state 대소문자 정규화(liquid/Liquid) 세 가지 전처리를 마친 뒤에야 실제 순증분을 다시 계산해야 한다.

② 외부 보강데이터 3종 실사용 가능성 검수

3. 외부 데이터 소스별 실사용 가능성 검수

B가 확보한 파일 3개(ChemSkin DB2.0 PDF, XGB 논문 supplementary xlsx/docx)를 직접 열어 구조·형식·결측·중복 관점에서 파이프라인 투입 가능 여부를 확인했다.

파일	구조 확인 결과	실사용 판정
43188_2022_168_MOESM2_ESM.xlsx (XGB descriptor 데이터)	545행×39열, 물리화학 descriptor 34개 전부 결측치 0건. 단 CASRN 컬럼에 datetime 오염 5건, CASRN 중복 88행(상충 43건), Physical state 대소문자 불일치.	[부분가능] 전처리 후 사용 가능 (캐스팅+dedupe+정규화 필요)
43188_2022_168_MOESM1_ESM.docx (descriptor 설명문서)	Table 1에 34개 descriptor 이름·정의 전부 문서화, 원 논문 개수와 1:1 일치. 결측/오류 없음.	[가능] 즉시 사용 가능
s00204-026-04406-y.pdf (ChemSkin DB2.0 논문)	본문 텍스트는 정상 추출되나, 핵심 Table 3(234종 CAS 리스트)이 PDF 내부에서 문자 단위로 회전 렌더링(upright=False)되어 있어 표준 텍스트 추출 시 234종 중 155종(66%)만 인식되고 나머지는 레이아웃 파싱 실패.	[불가] 구조적으로 즉시 사용 불가 (raw data 재확보 필요)

※ ChemSkin DB2.0의 "6종 겹침" 결론은 155종(추출 성공분) 기준으로 계산됐을 가능성이 있어, 전체 234종 기준 재검증이 필요하다. 234종 전체 CAS 리스트를 신뢰성 있게 확보하려면 PDF 뷰어로 수동 대조하거나 저자(Kyung-Min Lim, 이화여대)에게 raw data(csv/xlsx) 제공을 요청하는 방법을 권장한다.

---

4. 다음 액션 제안

☐ CASRN 12건: 처리방침(제외/플래그/근사치) 결정 — 3주차 라벨링 단계에서 MIX433 이상케이스와 함께 논의

☐ XGB xlsx: CASRN 문자열 캐스팅 + 중복 88건 dedupe/상충해소 + Physical state 정규화 스크립트 작성 → 순증분 재계산

☐ ChemSkin DB2.0: 234종 전체 CAS 리스트 확보(PDF 수동 대조 또는 저자 문의) 후 겹침 재검증

본 리포트는 skin_irritation.xlsx(Data_invivo), 43188_2022_168_MOESM1/2_ESM(docx/xlsx), s00204-026-04406-y.pdf 원본 파일을 pandas/pdfplumber/python-docx로 직접 재현하여 작성했다.