연구계획서

NTP ICE 혼합물 EPA 자극성 분류 데이터 기반 화장품 제형의 피부·안 자극성 예측
— 도메인 전이(Domain Transfer) 및 적용범위(Applicability Domain) 정량화 —

작성일: 2026년 7월 22일

1. 연구 필요성

1.1 화장품 안전성 평가 방식의 전환 요구

화장품 원료 및 제형의 피부·안(眼) 자극성 평가는 전통적으로 동물실험(Draize test)에 의존해왔으나, EU를 비롯한 주요 시장에서 화장품 원료에 대한 동물실험이 금지되었고, 3R 원칙(Replacement, Reduction, Refinement)에 따라 in vitro·in silico 대체 평가법에 대한 수요가 커지고 있음.

1.2 예측 타깃 및 데이터 소스 전환 배경

본 연구는 당초 화학구조 기반으로 성분의 제품범주별 최대허용농도(MAC)를 전이(transfer) 예측하는 방향으로 검토되었으나, 지도교수님 검토 과정에서 MAC이 대부분 단일 성분(single substance) 단위로 산출·관리되며 제형(mixture) 단위 MAC 데이터가 대규모로 축적된 공개 데이터베이스는 확인되지 않는다는 문제가 제기됨.

이에 혼합물/제형 단위 독성 데이터가 비교적 풍부한 공개 데이터베이스인 NTP ICE(Integrated Chemical Environment)의 skin/eye irritation 데이터셋(ICE Search를 통해 skin_irritation.xlsx, eye_irritation.xlsx로 직접 다운로드하여 확인)을 검토함. 그 결과 두 가지가 확인됨.

① MAC 또는 이에 준하는 필드(safe use concentration, margin of safety 등)는 두 데이터셋 어디에도 존재하지 않음. ② 예측 라벨로 검토했던 GHS Classification은 제형(Mixture) 단위 레코드에는 전혀 부여되어 있지 않고(skin_irritation의 Data_invivo 시트: Mixture 행 1,799건 중 GHS 값이 채워진 행 0건 / eye_irritation의 Data 시트: Mixture 행 983건 중 0건), 오직 단일 성분(Chemical) 행에만 부여되어 있음(skin 79/79건, eye 241/241건 100% 충족). 즉 GHS 라벨을 그대로 채택하면 mixture 단위 연구가 성립하지 않음.

반면 같은 mixture 행에는 EPA Classification(미국 EPA의 FIFRA 농약 라벨링 체계에 따른 4단계 급성 자극성 등급)이 거의 전량 채워져 있음을 확인함(skin: 1,799/1,799건 100%, eye: 978/983건 99.5%). 이에 따라 예측 라벨을 GHS 대신 EPA Classification(4단계)으로 채택하고, 학습 데이터 소스를 NTP ICE의 mixture 데이터로 확정함.

1.3 NTP ICE 혼합물 데이터의 특성과 화장품 도메인과의 간극

실제 다운로드한 데이터에서 mixture 레코드의 Reference는 대부분 "FIFRA data"로, 살균제·살충제·가정용 살충제 스프레이 등 농약/산업용 화학제품이 주를 이룸(예: Captan 4L 살균제, Raid Roach & Ant Killer, Vapona Concentrate Insecticide 등). ICE에는 화장품만 별도로 모아둔 서브셋은 없음. 이는 화장품 제형(계면활성제·보습제·방부제·향료 조합)과 성분군 구성 및 농도 분포가 다를 수 있음을 의미하며, 학습 도메인(ICE mixture)과 적용 도메인(화장품 제형) 간의 도메인 갭(domain gap)이 본 연구가 정면으로 다뤄야 할 핵심 난제가 됨.

또한 EPA Classification은 GHS와 유사한 목적(자극성 위험도에 따른 단계 분류)을 가지지만 서로 다른 규제 체계이며 등급 개수·경계 기준이 동일하지 않음(EPA는 Category 1~4, GHS eye는 1/2A/2B/무분류). 따라서 본 연구의 결과는 "EPA 체계 기준 자극성 등급(순서형)"으로 명시하고, GHS와의 1:1 등치를 주장하지 않음.

1.4 완성 제형 단위 예측의 필요성

화장품·산업용 제형 모두 단일 성분이 아닌 다수 성분의 혼합물이며, 실제 자극성은 성분 간 상호작용(예: 계면활성제 블렌드의 비선형 효과)에 의해 단순 합산과 다르게 나타나는 경우가 많음. 완성 제형 단위에서 이를 사전에 스크리닝할 수 있는 예측 모델은 개별 성분 정보만으로 접근하기 어려운 문제를 보완할 수 있음.

1.5 예측값과 함께 적용범위(applicability domain)를 제시해야 하는 이유

본 연구는 서로 다른 두 도메인(ICE의 농약/산업용 제형, 화장품 제형) 사이의 전이를 다루므로, 학습에 사용된 제형들과 화학적 조성이 유사한 화장품 제형에 대해서만 예측을 신뢰할 수 있음. 단일 예측값만 제시하는 대신 학습 도메인과의 조성 유사도 기반 적용범위(AD)를 함께 제시하면, 전이 예측을 신뢰할 수 있는 화장품 제형과 여전히 확인시험이 필요한 제형을 구분하는 근거로 활용할 수 있음.

2. 연구 목적

1. NTP ICE의 mixture/formulation 단위 skin·eye irritation 데이터(skin_irritation.xlsx의 Data_invivo, eye_irritation.xlsx의 Data 시트)를 이용하여, 성분 조성(성분명·CAS, 함량 비율 Percent_Active_Ingredient)으로부터 제형 전체의 EPA Classification 등급(4단계: Category 1 부식성/불가역 손상 ~ Category 4 무자극)을 예측하는 모델을 개발한다.

2. ICE mixture 데이터(농약/산업용 화학제품 위주)로 학습한 모델을, 화학적 조성이 다른 화장품 제형에 적용할 때 발생하는 도메인 갭을 정량화하고, 소규모 화장품 실측·문헌 자극성 데이터를 이용한 미세조정(fine-tuning) 전이학습 방법론을 설계·비교한다.

3. EPA 4단계 등급의 극심한 클래스 불균형(예: skin invivo mixture 데이터에서 Category 4가 1,434/1,799건, 약 80%를 차지)을 고려하여, 4단계 다분류와 이분류(예: Category 1~2 vs 3~4)를 함께 평가하는 이중 검증 체계를 설계한다.

4. 학습 도메인(ICE mixture)과 적용 도메인(화장품 제형) 간 성분 조성 공간의 유사도를 기준으로 적용범위(applicability domain)를 정의하여, 전이 예측을 신뢰할 수 있는 화장품 제형 영역과 확인시험이 필요한 영역을 구분하는 기준을 제시한다.

3. 연구 주제

"NTP ICE 혼합물 EPA 자극성 분류 데이터 기반 화장품 제형의 피부·안 자극성 예측: 도메인 전이 및 적용범위 정량화"

(영문 부제 예시: Transferring Mixture-Level EPA Skin/Eye Irritation Classification Models from NTP ICE to Cosmetic Formulations: A Domain Adaptation Approach with Applicability Domain Quantification)

4. 연구 내용

구성요소	내용
① NTP ICE 혼합물 데이터 확보	ICE Search(ice.ntp.niehs.nih.gov)에서 다운로드한 skin_irritation.xlsx(Data_invivo 시트, Mixture 행 1,799건, EPA classification 100% 충족), eye_irritation.xlsx(Data 시트, Mixture 행 983건, EPA Classification 99.5% 충족)를 학습 데이터로 확정
② 성분 조성 파싱 및 정규화	각 mixture(Formulation_ID)별 성분명(Chemical_Name)·CAS(CASRN)·활성성분 비율(Percent_Active_Ingredient)을 추출. 단, 다운로드 데이터 기준 성분이 1개만 명시된 제형이 상당수(예: eye 612건 중 379건, 약 62%)이므로 결측·단일성분 제형 처리 방침을 별도로 수립
③ 화장품 제형 데이터 수집 (전이 적용 대상)	공개 화장품 전성분표, 특허문헌 제형 예시 등에서 성분 조성(성분명+함량 추정치)을 수집. 학습용이 아닌 모델을 적용·검증할 타깃 도메인 데이터셋으로 구성
④ 화장품 소규모 실측 검증셋 구축	문헌에 보고된 화장품/계면활성제 블렌드의 실측 patch test·in vitro(EpiSkin, EpiOcular 등) 결과를 최소 규모로 수집하여 전이 성능 평가용 held-out 검증셋으로 구성

⑤ 클래스 불균형 대응 라벨링 설계	EPA Classification 4단계(Category 1~4) 다분류와, 이를 축약한 이분류(예: 1~2 vs 3~4)를 동시에 산출하는 라벨링 파이프라인 구현. skin invivo 데이터의 Category 4 비중(약 80%)을 고려한 재샘플링·클래스 가중치 전략 설계
⑥ 전이학습 모델 개발	(a) ICE mixture 데이터로 사전학습 후 화장품 소규모 데이터로 미세조정, (b) 미세조정 없는 zero-shot 전이, (c) 화장품 데이터만으로 학습한 소규모 모델을 비교
⑦ 도메인 갭 및 적용범위(AD) 평가	ICE mixture 도메인(농약/산업용)과 화장품 도메인 간 성분 조성 공간의 거리를 측정하고, AD 내부/외부 화장품 제형에 대한 전이 예측 성능 차이를 분석
⑧ 결과 정리 및 발표 준비	학술제 제출용 초록, 포스터/발표자료, 최종 보고서 작성

5. 연구 방법

5.1 NTP ICE 데이터 전처리

skin_irritation.xlsx(Data_invivo)와 eye_irritation.xlsx(Data)에서 Mixture 컬럼이 'Mixture'인 행만 필터링. Endpoint가 'EPA classification'(skin) / 'EPA Classification'(eye)인 레코드의 Response 값(Category 1~4)을 라벨로 사용. Formulation_ID 기준으로 그룹화하여 제형별 성분 조성 벡터를 구성.

5.2 결측·단일성분 제형 처리

성분이 1개만 명시된 제형(전체 mixture의 절반 내외)은 활성성분 단독 기여로 간주하는 baseline 처리와, 다성분 제형만으로 별도 서브셋을 구성해 학습하는 방식을 병행 비교하여 결측이 모델 성능에 미치는 영향을 분석.

5.3 화장품 제형(타깃 도메인) 데이터 수집

공개 화장품 전성분표, 특허문헌 제형 예시에서 성분명+함량 추정치를 수집. 학습에 직접 사용하지 않고 모델의 적용 대상 및 미세조정용 소규모 데이터로만 활용.

5.4 전이학습 방법론

사전학습-미세조정: ICE mixture 데이터로 성분 조성 → EPA 자극성 등급 관계를 사전학습한 후, 화장품 소규모 데이터로 미세조정. Zero-shot 전이: 미세조정 없이 ICE 사전학습 모델을 화장품 제형에 직접 적용. 세 방식(zero-shot, 미세조정, 화장품 전용 소규모 학습)의 성능을 비교하여 도메인 전이의 효과와 한계를 규명.

5.5 모델 개발 및 클래스 불균형 대응

4단계 다분류(Category 1~4)와 이분류(1~2 vs 3~4) 두 방식으로 각각 Random Forest/XGBoost 등 트리 기반 모델을 학습. 클래스 불균형에 대해 class_weight 조정, 오버샘플링(SMOTE 등)을 비교. 평가지표: 다분류는 macro F1-score·혼동행렬, 이분류는 F1-score·ROC-AUC.

5.6 도메인 갭 및 적용범위(Applicability Domain) 설정

ICE mixture 도메인(농약/산업용)과 화장품 도메인의 성분 조성 벡터 공간 내 거리(예: 성분군 분포, Tanimoto 유사도 등)를 측정하여 AD를 정의하고, AD 내부/외부 화장품 제형에 대한 예측 오차 차이를 비교 분석.

5.7 연구 수행 체계 및 사용 도구

연구팀 내 역할을 ICE 데이터 전처리, 화장품 데이터 수집, 모델링, 도메인 갭/AD 검증 등으로 분담. Python(pandas, scikit-learn, XGBoost, imbalanced-learn), 문헌 조사(RISS, PubMed 등) 활용.

6. 일정 계획 (2026.08.01 ~ 2026.11.06, 러프 계획)

기간	주요 활동

8/1 ~ 8/15	주제 확정, NTP ICE 다운로드 데이터(skin_irritation.xlsx, eye_irritation.xlsx) 상세 탐색적 분석(EDA), 관련 문헌(FIFRA/EPA 자극성 분류, 도메인 적응/전이학습 선행연구) 조사, 역할 분담
8/16 ~ 9/15	ICE mixture 데이터 전처리(성분 조성 파싱, 결측·단일성분 제형 처리), 화장품 제형(전성분표) 데이터 수집, 성분명-CAS 매핑
9/16 ~ 9/30	클래스 불균형 대응 라벨링(4단계/이분류) 파이프라인 구축, 전이학습 파이프라인(사전학습+미세조정, zero-shot) 구축
10/1 ~ 10/20	모델 개발 및 초기 실험, 화장품 소규모 검증셋을 통한 성능 비교
10/21 ~ 10/31	도메인 갭 분석, AD 내/외 오류 분석, 모델 보완
11/1 ~ 11/6	학술제 발표자료(포스터/PPT) 및 최종 보고서 작성, 발표 리허설

※ 위 일정은 데이터 수집 난이도 및 중간 결과에 따라 조정 가능한 러프한 계획임 (특히 클래스 불균형 대응 및 화장품 도메인과의 성분군 중복 정도가 전체 일정과 모델 성능에 가장 큰 영향을 줄 것으로 예상됨).

※ 본 연구계획서는 "화학구조 기반 MAC 전이예측" → "NTP ICE mixture 기반 GHS 자극성 예측" 버전을 거쳐, 실제 NTP ICE 다운로드 데이터(skin_irritation.xlsx, eye_irritation.xlsx)를 직접 분석한 결과에 따라 예측 라벨을 GHS Classification에서 EPA Classification으로 최종 수정한 것임. GHS는 이 데이터셋의 mixture 레코드에 전혀 부여되어 있지 않고(성분 단위에만 존재) EPA Classification만 mixture 단위로 거의 전량 확보되어 있음을 실제 데이터 분석으로 확인함.