선행연구 요약 (상세)

STopTox: An in Silico Alternative to Animal Testing for Acute Systemic and Topical Toxicity

저자: Borba JVB, Alves VM, Braga RC 외 11명 (UNC Chapel Hill / NICEATM 등)

발표: 2022년 2월 · Environmental Health Perspectives 130(2):027012

DOI: 10.1289/EHP9341 · 전문 확인: PMC8863177

링크: https://pubmed.ncbi.nlm.nih.gov/35192406/ (전문: https://pmc.ncbi.nlm.nih.gov/articles/PMC8863177/)

관련 단계: ③④⑤ 자극성 예측 모델 · 화장품/농약 겸용 적용 · 적용범위(AD)

1. 핵심 내용 요약

농약·의약품·화장품 규제 평가에 필요한 급성독성 "6-pack"(피부 감작성, 피부 자극/부식성, 안 자극/부식성, 급성 경구·흡입·경피 독성)을 동물실험 없이 예측하는 QSAR 앙상블 모델 시스템을 제시한다. 동물실험 대체 원칙(3R: Replacement/Reduction/Refinement)에 따라, 농약 1건 등록에 최대 50만 달러, 발암성 시험 하나에만 180만 달러가 드는 동물실험 비용 문제를 해결하려는 목적이다.

각 endpoint별로 공개된 데이터셋 중 가장 큰 규모를 큐레이션했으며(피부 감작성 기준 원본 10,861건 → 최종 1,000개 화합물), 분자 구조 기반 서술자(molecular descriptor)를 활용한 QSAR 앙상블 모델을 구축했다. 외부검증셋에서 70~77%의 정확분류율(CCR)을 달성했으며, 웹 포털(stoptox.mml.unc.edu)로 공개되어 누구나 화학물질의 독성을 스크리닝할 수 있다.

연구 진행 과정을 요약하면 다음과 같다:

① 데이터 수집 — REACH·ICCVAM·ToxValDB·NICEATM 등 공개 데이터베이스에서 6개 endpoint 원시 데이터를 모두 수집 (총 6만 건 이상)

② 데이터 curation — OECD 표준 미준수·중복·상충 데이터를 단계적으로 제거해 신뢰할 수 있는 데이터만 남김 (평균 52~92% 감소)

③ 분자 표현 계산 — 남은 화합물마다 Morgan fingerprint·MACCS keys·Mordred descriptor 3종을 계산

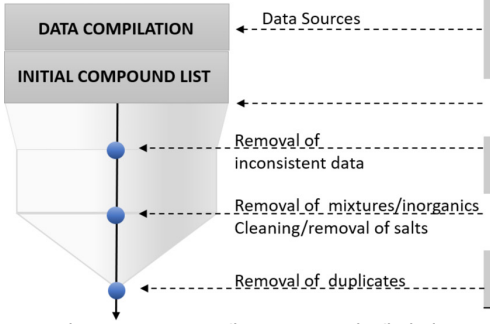
④ 모델 학습 — 서술자별로 Random Forest 모델 3개를 각각 학습, 5-fold 외부교차검증으로 성능 평가

⑤ 컨센서스 예측 — 3개 모델의 예측을 다수결로 종합하고 Y-randomization으로 우연 학습 여부 검증

⑥ 웹 서비스화 — 학습된 모델을 웹 애플리케이션(STopTox)으로 배포해 누구나 SMILES 입력만으로 예측 결과를 받아볼 수 있게 함

2. 데이터 출처 및 구성

6개 endpoint 모두 REACH(유럽 화학물질 등록·평가 규정), ICCVAM, ToxValDB, NICEATM CATMoS 워크숍 데이터 등 공개 규제 데이터베이스에서 원시 레코드를 수집한 뒤, 엄격한 curation을 거쳐 최종 데이터셋을 확정했다. curation은 5단계로 진행됐다 — (1) OECD 표준을 따르지 않은 데이터·QSAR/read-across 예측값 제외 → (2) 혼합물·무기물·유기금속화합물 제거 → (3) 염(salt) 세정 및 화학형(chemotype) 정규화 → (4) 중복 레코드 제거(결과가 일치하면 1건만 채택, 상충하면 해당 화합물 전체 제외) → (5) 수작업 검수.



	Skin Sensitization	Skin Irritation/ Corrosion	Eye Irritation/ Corrosion	Acute Dermal Toxicity	Acute Inhalation Toxicity	Acute Oral Toxicity
Data Sources	ECHA/ ICCVAM	ECHA	ECHA/ Literature	ECHA/ ToxValDB/ Creton et al.	ECHA/ ToxValDB	NICEATM
	10,861	5,274	7,332	29,824	8,176	8,994
Removal of inconsistent data	2,347	1,631	7,196	5,259	2,061	8,981
Removal of mixtures/inorganics Cleaning/removal of salts	1,110	1,326	5,985	4,601	1,637	8,978
Removal of duplicates	1,000	1,012	3,545	2,616	681	8,442

그림 1. STopTox 6개 endpoint의 데이터 curation 단계별 화합물 수 변화 (원문 Figure 2). 피부 감작성은 10,861건에서 1,000개로(90.8% 감소), 급성 경구는 8,994건에서 8,442개로(6.1% 감소)만 줄어드는 등 endpoint마다 감소율이 크게 다르다.

자료: Borba JVB et al. 2022, Environmental Health Perspectives 130(2):027012 (원문 그림 인용, PMC8863177)

Endpoint	원본 레코드	최종 화합물 수	클래스 분포
피부 감작성	1,060(ICCVAM)+10,588(REACH)	1,000	감작 481 / 비감작 519
피부 자극/부식	5,274 (REACH)	1,012 (undersampling 후 554)	부식 40, 자극 277, 비자극 695
안 자극/부식	7,332 (REACH+문헌)	3,547 (undersampling 후 2,292)	자극 1,145 / 비자극 2,400
급성 경피	29,824 (REACH·ToxValDB·문헌)	2,622 (undersampling 후 764)	독성 382 / NC 2,234
급성 흡입	8,176 (REACH·ToxValDB)	681	독성 345 / NC 336 (자연균형)
급성 경구	8,994 (NICEATM CATMoS)	8,442	독성 4,803 / NC 3,639

※ NC = Not Classified. curation 과정에서 상충(discordant) 데이터 쌍은 제거됨(피부감작 5쌍, 피부자극 29쌍, 급성경피 143쌍, 급성흡입 26쌍 제거). 클래스가 불균형한 endpoint(피부/안 자극, 급성 경피)는 소수 클래스와 화학적으로 유사한(Tanimoto 유사도 기준) 다수 클래스 화합물만 남기는 언더샘플링을 적용했다.

2-1. 기존 6-pack 예측 도구와의 차이

논문은 Danish QSAR database, TOPKAT, ACD/Percepta, CASE Ultra, ToxTree, Derek Nexus, OECD QSAR Toolbox, VEGA, CATMoS(OPERA), PredSkin, RASAR 등 기존 11개 도구를 비교했다(원문 Table 1). 대부분 6-pack 중 1~5개 endpoint만 지원하거나 상업용 라이선스(TOPKAT, ACD/Percepta, CASE Ultra, Derek Nexus, RASAR)로 제한되어 있었다. STopTox는 6개 endpoint를 모두 무료로, 하나의 웹 포털에서 동시에 제공하는 최초의 공개 도구라는 점을 강조한다.

3. 모델링 파이프라인

분자 표현은 Morgan fingerprint, MACCS keys, Mordred descriptor 3종을 병렬로 사용했고, 각 서술자로 Random Forest 모델을 각각 학습한 뒤 3개 모델의 예측을 다수결(2/3 이상 일치)로 종합하는 컨센서스 방식을 채택했다. 성능 평가는 5-fold external cross-validation으로, 전체 데이터를 5등분해 매 반복마다 20%를 테스트셋으로 사용했다(학습셋은 다시 내부적으로 train/validation으로 나눠 하이퍼파라미터를 튜닝). Y-randomization(라벨을 무작위로 섞어 10회 반복)으로 모델이 우연이 아닌 실제 신호를 학습했는지 검증했고, z-cutoff와 Dice 유사도를 결합해 적용범위(Applicability Domain)를 정의했다.

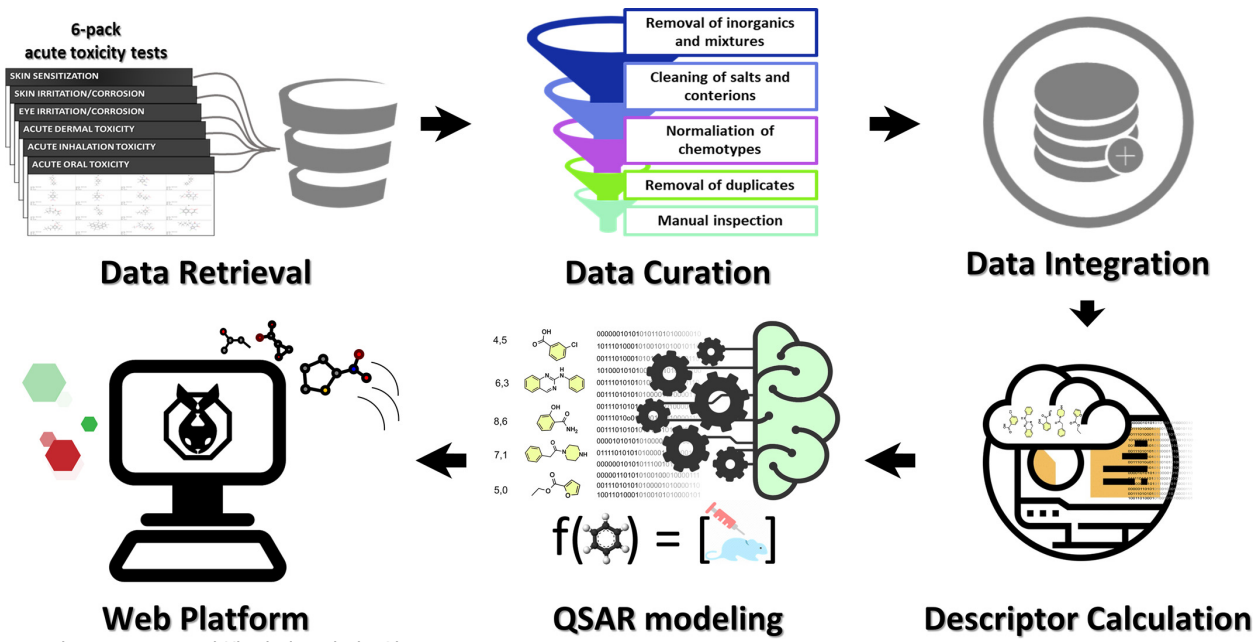


그림 2. STopTox 전체 파이프라인 (원문 Figure 1) — Data Retrieval → Data Curation → Data Integration → Descriptor Calculation → QSAR Modeling → Web Platform 6단계로 구성된다.

자료: Borba JVB et al. 2022, Environmental Health Perspectives 130(2):027012 (원문 그림 인용, PMC8863177)

4. 성능 결과

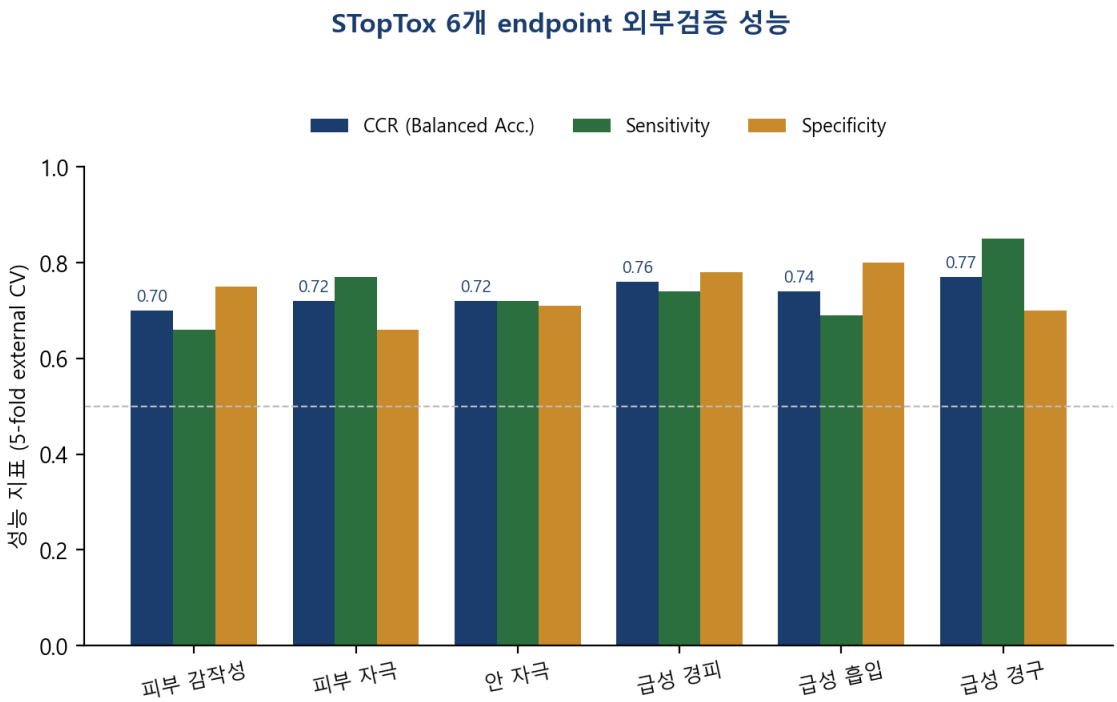


그림 3. 6개 endpoint의 5-fold 외부검증 성능(CCR/Sensitivity/Specificity). 전체 CCR은 0.70~0.77 범위. 점선은 무작위 추정 수준(0.5). (본문 Table 2 수치를 바탕으로 자체 시각화)

외부 문헌에서 알려진 독성물질 25개를 별도로 검증했을 때 18개(72%)를 정확히 예측했다. 예를 들어 화장품에 흔히 쓰이는 계면활성제 성분인 라우릴 설페이트(Lauryl Sulphate)는 모델이 정확히 피부 자극물질로 예측했고, 제초제 글리포세이트(Glyphosate)와 소독제 글루타르알데하이드는 안 자극물질로 정확히 예측됐다. 반면 어류 마취제 MS-222는 실제로는 자극성이 있으나 모델은 무자극(Not Classified)으로 예측해 한계도 드러났다.

또한 이 모델을 화장품 성분 데이터베이스(CosIng, 3,850개 화합물)와 REACH(10,465개)에 적용한 결과, CosIng 화합물 중 2,695개가 최소 1개 endpoint에서 독성으로 예측되었고 1,155개는 모든 endpoint에서 무독성으로 예측되었다 — 즉 농약/산업용 데이터로 학습한 모델을 화장품 성분에 실제로 적용해본 사례이다.

4-1. 기존 상업용 도구(RASAR)와의 비교

Endpoint	RASAR 화합물수/CCR	STopTox 화합물수/CCR
피부 감작성	7,670 / 0.88	1,000 / 0.70
피부 자극/부식	46,331 / 0.86	1,012 / 0.72
안 자극/부식	48,767 / 0.84	3,547 / 0.77
급성 경피	11,252 / 0.92	2,622 / 0.77
급성 흡입	11,369 / 0.91	681 / 0.76
급성 경구	32,411 / 0.90	8,465 / 0.78

RASAR(Luechtefeld et al. 2018)는 평균 5배 더 많은 데이터로 학습해 CCR이 평균 10%p 더 높지만, curation이 엄격하지 않아 중복·상충 데이터가 많이 남아있을 수 있다는 우려가 제기된 바 있다. 저자들은 "데이터 양보다 curation 품질이 모델의 실제 신뢰성을 좌우한다"는 점을 이 비교를 통해 강조한다.

5. 웹포털 구조 및 실제 예측 화면

STopTox 웹 앱은 Python Flask(백엔드, 머신러닝 추론 실행)로 서버를 구성하고, 프론트엔드는 Angular(TypeScript)로 개발했으며, Docker와 Docker-Compose로 컨테이너를 오케스트레이션해 배포했다. 사용자가 분자 편집기에 화학구조를 그리거나 SMILES 문자열을 입력하고 "Predict STopTox" 버튼을 누르면, 6-pack 각 endpoint에 대한 독성/비독성 예측과 적용범위(AD) 기반 신뢰도(confidence)를 함께 받는다.

프래그먼트 기여 지도 기능은 특정 원자·작용기를 제거했을 때 예측값이 얼마나 바뀌는지를 계산해 색상(빨강 실선=독성증가 기여, 초록 점선=독성감소 기여)으로 시각화한다. 아래 그림은 헤나 타투에 흔히 쓰여 접촉성 알레르기를 유발하는 성분인 N-phenyl-p-phenylenediamine 하나에 대해 6개 endpoint 전체를 예측한 실제 결과 화면으로, 사용자가 웹포털에 화합물을 입력했을 때 받는 출력과 동일한 형태다.

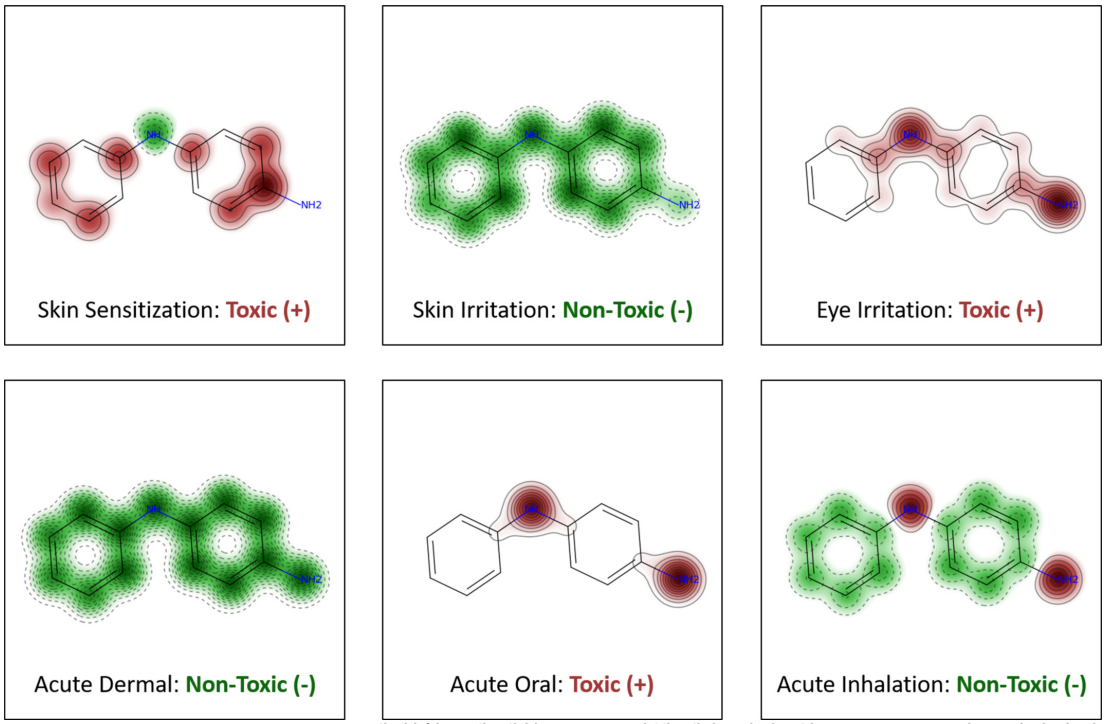


그림 4. N-phenyl-p-phenylenediamine 1개 화합물에 대한 6-pack 전체 예측 결과 (원문 Figure 4). 피부 감작성·안 자극 Toxic(+), 피부 자극·급성 경피·급성 흡입 Non-Toxic(-), 급성 경구 Toxic(+)으로 예측되었으며, 각 endpoint마다 어떤 원자/작용기가 독성 판정에 기여했는지 다른 색상 패턴으로 나타난다.

자료: Borba JVB et al. 2022, Environmental Health Perspectives 130(2):027012 (원문 그림 인용, PMC8863177)

전체 데이터셋과 모델 학습 코드는 GitHub(github.com/joyvb/stoptox)에 공개되어 있어, 우리 팀이 웹 연동을 구현할 때 참고 구조(백엔드-프론트엔드 분리, 컨테이너 배포, SMILES 입력 → 예측 API 호출 → 결과·신뢰도·근거 시각화 반환)로 그대로 벤치마킹할 수 있다.

6. 우리 연구에 어떻게 활용할 수 있는가

① 피부/안 자극성을 화장품·농약 두 도메인에 걸쳐 정확히 다룬 논문으로, 우리 연구의 ③④⑤ 단계(자극성 예측 모델 구축 → 화장품 데이터 적용 → 결과 도출)와 거의 일대일로 대응된다.

② QSAR 서술자 기반 접근(Morgan FP, MACCS, Mordred)을 우리의 트리기반 모델(RF/XGBoost) 피처 엔지니어링에 참고할 수 있고, 외부검증 CCR 0.70~0.77을 우리 모델의 성능 벤치마크로 삼을 수 있다.

③ "농약/산업용 데이터로 학습 → 화장품(CosIng) 성분에 실제 적용"한 사례가 이미 존재한다는 점은 우리 연구 구조의 타당성을 뒷받침하는 선례로 인용할 수 있다.

④ z-cutoff + Dice 유사도 기반 AD 설정 방식은 우리가 ICE mixture 도메인과 화장품 도메인 간 적용범위를 정의할 때 구체적인 참고 알고리즘이 될 수 있다.

⑤ 만약 우리 모델의 성능이 충분히 확보되어 추후 웹 서비스로 연동하게 된다면, STopTox의 Flask+Angular+Docker 구조와 "SMILES/성분 입력 → 예측 결과+신뢰도+색상 기여 지도 반환" 형태의 UX를 참고 사례로 삼을 수 있다.

⑥ RASAR와의 비교(데이터량 대비 curation 품질)는, 우리가 화장품 데이터 수집 시 "양보다 품질"을 우선해야 한다는 근거로 활용할 수 있다.

※ 위 수치·표는 PMC8863177(전문) 확인 내용을 기반으로 작성함. 그림 1(curation), 2(workflow), 4(fragment map)는 원문 Figure를 그대로 인용한 것이고, 그림 3(성능 그래프)만 본문 Table 2 수치를 바탕으로 자체 시각화한 것임.