선행연구 요약: PFAS 급성독성 전이학습 모델

Uncertainty-Informed Deep Transfer Learning of Perfluoroalkyl and Polyfluoroalkyl Substance Toxicity

저자	Feinstein J, Sivaraman G, Picel K, Peters B, Vázquez-Mayagoitia Á, Ramanathan A, MacDonell M, Foster I, Yan E (Argonne National Laboratory, 미국 에너지부)

발표	2021년 12월 · Journal of Chemical Information and Modeling (JCIM) 61(12)
DOI	10.1021/acs.jcim.1c01204
코드/데이터	github.com/AI4PFAS/AI4PFAS (공개)
관련 단계	④ 전이학습 모델 개발 · 도메인 갭/적용범위(AD) 평가

전이학습 | 불확실성 정량화 | 급성독성(LD50) | 소규모 타깃 도메인

1. 핵심 내용 요약

PFAS(과불화·다불화 알킬 화합물)는 산업·소비재 전반에 광범위하게 쓰이지만, 실측 독성 데이터가 극히 부족한 화학물질군이다. 이 연구는 이러한 데이터 희소성 문제를 **전이학습(transfer learning)**으로 해결하고자, 우선 공개된 일반 유기화합물의 급성 경구독성(rat LD50) 데이터를 모두 모아 대규모 소스(source) 모델을 구축한 뒤, 이를 PFAS라는 소규모 타깃(target) 도메인으로 지식을 전이시키는 파이프라인을 제시한다.

가장 큰 특징은 단순히 예측값만 내놓는 것이 아니라, **예측의 불확실성(uncertainty)을 정량화**하여 "이 예측을 얼마나 신뢰할 수 있는가"까지 함께 제공한다는 점이다. 이를 위해 전이학습된 모델을 **SelectiveNet** 구조에 결합해, 확신이 낮은 예측에 대해서는 판단을 보류(abstain)할 수 있도록 설계했다.

2. 연구 배경 및 문제의식

PFAS는 화학구조적으로 매우 다양한 화합물군이며, 이 중 실제 동물실험으로 급성경구독성이 측정된 화합물은 극소수에 불과하다. 반면 in vivo 동물실험은 비용과 시간, 윤리적 부담이 크기 때문에, 수천 개에 달하는 PFAS 화합물 전체를 실험으로 검증하는 것은 현실적으로 불가능하다. 저자들은 이 문제를 해결하기 위해 "PFAS와 화학적으로 가장 가까운 화합물군에서 지식을 전이해오되, 예측이 불확실한 영역은 스스로 인지하고 걸러내는" 접근을 택했다.

3. 데이터셋 구성

구분	구성	비고
소스(source) 데이터	EPA TEST, NIH CATMoS, NTP 등에서 수집한 일반 유기화합물 rat 경구 LD50 데이터를 통합 (LDToxDB)	InChIKey 기준 중복 화합물 제거, LD50은 −log(mol/kg)로 정규화
전이(transfer) 데이터	C–F 결합을 2개 이상 포함하는 불소화합물("PFAS-like") 약 518~519개, 실측 LD50 보유	PFAS 전체 중 화학적으로 소스 도메인과 가장 가까운 서브셋
최종 타깃(target) 대상	실측 독성값이 없는 PFAS 화합물 8,000여 개	전이학습 모델로 예측 + 불확실성(신뢰도) 함께 산출

4. 모델링 파이프라인

1	2	3	4	5
소스 모델 비교 (RF · DNN · GCN · Gaussian Process)	최고 성능 소스 모델 선정 (DNN 앙상블)	PFAS-like 518개로 전이학습(fine-tuning)	SelectiveNet 결합 (불확실성 정량화)	전체 PFAS(8천여 개) 예측 + 신뢰도 산출

저자들은 먼저 Random Forest, 심층신경망(DNN), 그래프 합성곱 신경망(GCN), 가우시안 프로세스 등 여러 머신러닝 기법으로 소스 모델을 구축·비교했고, 이 중 **DNN 앙상블**이 가장 우수한 성능을 보여 전이학습의 기반 모델로 채택했다. 이후 화학적으로 PFAS와 가장 유사한 서브셋(PFAS-like, 518개)으로 모델을 미세조정(fine-tuning)하여, 실측값이 없는 광범위한 PFAS 화합물(8천여 개)에 대한 예측과 신뢰도를 함께 산출하는 2단계 전이 전략을 취했다.

4-1. SelectiveNet 기반 불확실성 정량화

모델의 표현(representation) 레이어를 세 개의 헤드(head)로 분기시켜 학습한다:

- **예측 헤드 f(x)** — LD50 값 자체를 예측
- **선택 헤드 g(x)** — 이 예측을 채택할지(신뢰 가능) 보류할지(abstain) 판단하는 분류기
- **보조 헤드 h(x)** — 표현 레이어의 학습을 보강하는 보조 과제

$$L(f, g) = r(f, g \mid S_k) + \lambda \cdot \max(0, (c - \phi(g \mid S_k)))^2$$

위 결합 손실함수에서 $r(f,g|S_k)$는 선택된 샘플에 대한 예측 위험도(risk), $\phi(g|S_k)$는 모델이 실제로 예측을 채택하는 비율(coverage), c는 목표 커버리지다. 이 risk-coverage 관계를 최적화하여, "어느 정도의 커버리지에서 예측 위험을 최소화할 수 있는가"에 해당하는 신뢰도 컷오프(cutoff)를 결정한다. 결과적으로 모델은 확신이 낮은 화합물에 대해서는 명확한 분류 대신 "판단 보류"를 반환할 수 있다.

왜 이 설계가 중요한가

일반적인 QSAR/전이학습 모델은 모든 입력에 대해 일단 하나의 예측값을 내놓지만, 학습 도메인과 거리가 먼 화합물에 대해서는 그 예측이 사실 신뢰할 수 없는 경우가 많다. 이 논문은 "예측을 하되, 자신 없는 경우를 스스로 표시한다"는 점에서 적용범위(Applicability Domain, AD) 개념을 모델 내부에 학습 가능한 형태로 통합했다는 의의가 있다.

⚠ 확인 필요 (전문 접근 제한)

이 논문은 JCIM(ACS) 정식본이 유료 구독 기반이고, 프리프린트(ChemRxiv) 원문도 접근이 제한되어 있어 초록·공개된 발췌문·학회 발표자료·GitHub 저장소 설명을 바탕으로 이 요약을 작성했다. 소스 모델별 정확한 성능 지표(R^2, RMSE, 커버리지-정확도 트레이드오프 수치 등)는 원문 표에서 직접 확인하지 못했으므로, 팀 발표자료에 구체적 수치를 인용하려면 GitHub(github.com/AI4PFAS/AI4PFAS) 코드/결과 파일이나 도서관 상호대차를 통한 원문 확인을 권장한다.

5. 우리 연구에 어떻게 활용할 수 있는가

1 파이프라인 구조 자체가 우리 연구의 원형(archetype)

"대규모 소스 도메인(일반 유기화합물) → 화학적으로 가까운 소규모 서브셋으로 전이 → 최종 광범위한 타깃 도메인 예측" 이라는 3단계 구조는, 우리의 "NTP ICE mixture(농약/산업용) → 화장품 소규모 실측 검증셋으로 미세조정 → 화장품 전성분표 전체 적용"과 정확히 동일한 논리입니다. 특히 "타깃과 가장 가까운 서브셋부터 먼저 검증한다"는 순서를, 우리도 화장품 데이터 중 ICE mixture와 성분 조성이 가장 유사한 제형부터 우선 검증하는 방식으로 채택할 수 있습니다.

2 AD(적용범위) 밖 영역 처리를 트리 기반 모델에 이식

SelectiveNet은 딥러닝 전용 구조라 RF/XGBoost에 그대로 이식할 수는 없지만, **핵심 아이디어**— "예측 확신도가 낮으면 분류를 보류하고 확인시험이 필요한 영역으로 표시한다"—는 트리 기반 모델에서도 구현 가능합니다. 예를 들어 RF의 클래스별 확률 분포(predict_proba)의 최댓값이 특정 임계값 미만이면 "AD 밖 / 확인시험 필요"로 별도 표시하는 방식입니다. 이는 우리의 연구목적 4번 ("전이 예측을 신뢰할 수 있는 화장품 제형 영역과 확인시험이 필요한 영역을 구분하는 기준 제시")을 구체적인 알고리즘 수준에서 뒷받침하는 참고 사례로 인용할 수 있습니다.

3 소스 모델 선택 근거 및 후속 확장 방향 제시

이 논문은 RF, DNN, GCN, 가우시안 프로세스를 비교했고 DNN이 최선이었다고 보고합니다. 이는 트리 기반 모델(RF/XGBoost)이 항상 최선이 아닐 수 있음을 보여주는 사례이므로, 발표 시 "우리는 해석 가능성과 소규모 데이터 적합성을 고려해 트리 기반 모델을 우선 채택했으나, 선행연구는 딥러닝 기반 모델이 더 우수할 가능성도 시사한다"는 식으로 한계 및 후속 연구 방향을 언급할 때 인용할 수 있습니다.

4 데이터 통합·중복 제거 방식 벤치마킹

이 연구팀은 EPA TEST, NIH CATMoS, NTP 세 기관의 서로 다른 LD50 데이터셋을 통합하면서 InChIKey 기준으로 중복 화합물을 식별·제거했습니다. 우리도 NTP ICE 외에 화장품 전성분표·특허문헌 등 여러 출처의 성분 데이터를 통합해야 하므로(연구내용 2·3번), 이 InChIKey 기반 중복제거 방식을 성분명–CAS 매핑 단계에 그대로 적용할 수 있습니다.

5 "불확실성 표시"를 우리 결과물의 차별점으로 강조

단순히 화장품 제형의 EPA Category를 예측하는 데 그치지 않고, "이 예측을 신뢰할 수 있는가"까지 함께 제시한다면 실무적 활용도가 높아집니다. 이 논문을 근거로, 우리 연구의 최종 산출물에도 단일 등급 예측값과 함께 신뢰도(또는 AD 내/외 여부)를 함께 제공하는 것을 목표로 설계했다고 발표에서 강조할 수 있습니다.

6. 참고문헌 표기

Feinstein, J., Sivaraman, G., Picel, K., Peters, B., Vázquez-Mayagoitia, Á., Ramanathan, A., MacDonell, M., Foster, I., & Yan, E. (2021). Uncertainty-Informed Deep Transfer Learning of Perfluoroalkyl and Polyfluoroalkyl Substance Toxicity. *Journal of Chemical Information and Modeling*, 61(12). https://doi.org/10.1021/acs.jcim.1c01204

본 요약본은 논문 초록, 학회 발표자료(ANL/Argonne, DOE PAGES), 공개 데이터 저장소(GitHub: AI4PFAS)의 공개된 정보를 바탕으로 작성되었으며, 저작권 보호를 위해 원문을 그대로 옮기지 않고 모두 자체적으로 바꾸어 서술했습니다. 정확한 수치·표가 필요한 경우 원문(JCIM 61(12), 2021) 확인을 권장합니다.