피부·안구 독성 예측 선행연구 정리

사용자 선정 논문 2편 요약: 핵심내용, 배경, 모델링 과정, 우리 연구 활용

구분	논문 1	논문 2
제목	AttentiveSkin: To Predict Skin Corrosion/Irritation Potentials of Chemicals via Explainable Machine Learning Methods	New Frontiers in AI-Nano Converged Platforms for Intelligent Diagnostics, Therapeutics, and Safety Evaluation
역할	피부 부식/자극성을 직접 예측한 ML 모델 논문	AI와 나노기술을 이용한 진단, 치료, 안전성 평가 흐름을 정리한 리뷰 논문
우리 연구와 연결	피부 독성 예측 모델 설계에 직접 참고 가능	화장품 제형, 특히 나노소재/전달체 안전성 평가와 AI 활용 배경으로 참고 가능

그림 1. 우리 연구에 가져올 수 있는 전체 흐름



이 그림은 원문 그림을 복사한 것이 아니라, 두 논문의 방법을 바탕으로 새로 정리한 연구 흐름도입니다.

1. AttentiveSkin 논문

항목	내용
논문 제목	AttentiveSkin: To Predict Skin Corrosion/Irritation Potentials of Chemicals via Explainable Machine Learning Methods
저자	Zejun Huang, Shang Lou, Haoqiang Wang, Weihua Li, Guixia Liu, Yun Tang
학술지	Chemical Research in Toxicology, 37(2), 361-373
출판 정보	2024년 1월 31일 온라인 공개, 2024년 2월 19일 출판
DOI / PMID	10.1021/acs.chemrestox.3c00332 / PMID: 38294881
논문 성격	피부 부식성과 피부 자극성을 예측하는 설명가능한 머신러닝 모델 개발 연구

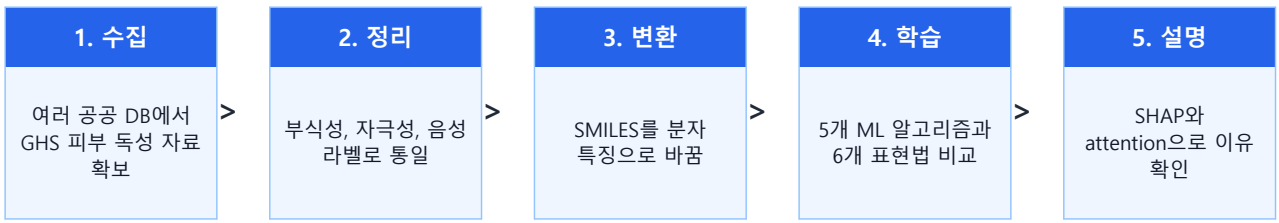
연구 배경

- 피부 부식성은 피부에 되돌리기 어려운 손상을 주는 성질이고, 피부 자극성은 붉어짐이나 염증처럼 비교적 덜 심한 손상을 일으키는 성질이다.
- 화학물질 안전성 평가는 예전에는 동물실험에 많이 의존했지만, 비용과 윤리 문제 때문에 컴퓨터 예측 모델의 필요성이 커졌다.
- 기존 모델들은 데이터 수가 부족하거나, 어떤 이유로 예측했는지 설명하기 어렵거나, 실제로 쓸 수 있는 프로그램 형태로 제공되지 않는 경우가 있었다.

핵심내용 요약

- 연구진은 6개의 정부 데이터베이스와 2개의 외부 데이터셋에서 피부 부식, 피부 자극, 음성 데이터를 모았다.
- 최종 데이터는 부식성 731개, 자극성 1283개, 음성 1205개 샘플로 구성되었다.
- 모델은 두 가지 문제를 따로 풀었다. 첫째는 부식성 vs 음성, 둘째는 자극성 vs 음성이다.
- 10-fold cross-validation에서 부식성 예측 최고 AUC는 97.1%, 자극성 예측 최고 AUC는 84.7%였다.
- SHAP와 attention weight를 이용해 어떤 분자 특징이 예측에 영향을 주었는지도 보여주었다.

그림 2. AttentiveSkin 모델링 과정



SMILES는 화학구조를 글자로 적은 형식입니다. 모델은 이 글자 또는 여기서 계산한 특징을 보고 독성을 예측합니다.

모델링 과정 자세히

- 1단계: 데이터 수집. 여러 데이터베이스에서 화학물질의 피부 부식성, 피부 자극성, 음성 정보를 모았다. 한 곳의 데이터만 쓰면 편향이 생길 수 있어서 여러 출처를 합쳤다.
- 2단계: 라벨 정리. 출처마다 표현이 다를 수 있으므로 GHS 기준에 맞춰 부식성, 자극성, 음성으로 다시 정리했다. 이 과정이 중요하다. 라벨이 흔들리면 모델도 흔들린다.
- 3단계: 학습 문제 나누기. 부식성과 자극성을 한 번에 예측하지 않고, 부식성 vs 음성, 자극성 vs 음성이라는 두 개의 이진분류 문제로 나누었다.
- 4단계: 분자 표현 만들기. 화학구조를 모델이 읽을 수 있게 바꾸었다. 예를 들어 분자 fingerprint, descriptor, 그래프 기반 표현처럼 구조 정보를 숫자나 그래프 형태로 바꾼다.
- 5단계: 여러 모델 비교. 연구진은 5가지 ML 알고리즘과 6가지 분자 표현을 조합해 여러 모델을 만들고 성능을 비교했다. 가장 좋은 조합을 찾는 방식이다.
- 6단계: 검증. 데이터를 10개 부분으로 나누어 번갈아 검증하는 10-fold cross-validation을 수행했다. 또한 외부 검증으로 기존 도구와 비교했다.
- 7단계: 해석. SHAP는 각 특징이 예측을 얼마나 밀어 올리거나 낮췄는지 보여준다. Attentive FP의 attention은 분자 안에서 모델이 어느 부분을 중요하게 봤는지 시각화한다.

우리 연구에서 활용 가능한 부분

- 피부 독성 예측 모델의 가장 직접적인 선행연구로 사용할 수 있다.
- 우리도 ICE/NICE 데이터 라벨을 정리할 때 부식성, 자극성, 음성처럼 기준을 명확히 나누는 방식을 참고할 수 있다.
- Random Forest나 XGBoost 같은 기본 모델과 그래프 기반 모델을 비교하는 연구 설계에 참고할 수 있다.
- 결과를 단순히 맞혔다고 끝내지 않고, SHAP나 attention으로 왜 그렇게 예측했는지 설명하는 방향을 가져올 수 있다.
- 화장품 성분의 SMILES가 있다면 이 논문처럼 구조 기반 예측을 시도할 수 있다.

2. AI-Nano Converged Platforms 논문

항목	내용
논문 제목	New Frontiers in AI-Nano Converged Platforms for Intelligent Diagnostics, Therapeutics, and Safety Evaluation
저자	Huijie Zhou, Jiming Xu, Xinyu Qin, Jing Zhang, Wenjiang Zou, Mohsen Shakouri, Jun Wu, Lvzhou Li, Yuping Li, Jianning Ding, Huan Pang
학술지	Chem & Bio Engineering, 3(6), 555-584
출판 정보	2026년 3월 28일 온라인 공개, 2026년 6월 25일 출판
DOI / PMID / PMCID	10.1021/cbe.5c00188 / PMID: 42376261 / PMCID: PMC13312061
논문 성격	AI와 나노기술을 결합한 진단, 치료, 안전성 평가 연구들을 정리한 리뷰 논문

연구 배경

- 나노소재는 크기, 표면 전하, 모양, 코팅, 응집 정도에 따라 생체 반응이 크게 달라진다.
- 이런 특성 때문에 단순한 실험 결과 몇 개만으로 안전성을 판단하기 어렵다.
- 논문은 ML이 복잡한 나노소재 데이터를 분석하고, 진단·치료·안전성 평가를 더 빠르고 똑똑하게 만드는 방향을 정리한다.

핵심내용 요약

- 이 논문은 직접 하나의 새 독성예측 모델을 만든 연구가 아니라, 여러 AI-나노 융합 연구를 모아 정리한 리뷰다.
- ML은 나노센서 신호 해석, 약물 전달 최적화, 나노소재 독성 예측, 임상 적용 문제 해결에 쓰일 수 있다고 설명한다.
- 안전성 평가에서는 나노소재의 물리화학적 특성, 생물학적 반응, 환경 독성 데이터를 함께 보는 것이 중요하다고 강조한다.
- 좋은 모델을 만들려면 표준화된 데이터, 해석가능한 알고리즘, 실험 결과를 다시 모델에 반영하는 반복 구조가 필요하다고 본다.

그림 3. 리뷰 논문이 정리한 안전성 평가 모델링 흐름



리뷰 논문이 직접 이 한 모델을 만든 것은 아니지만, 여러 연구에서 공통적으로 쓰이는 안전성 평가 흐름을 이렇게 정리할 수 있습니다.

모델링 과정 자세히

- 1단계: 입력 변수 정하기. 나노소재는 단순히 성분명만으로 설명하기 어렵다. 입자 크기, 표면 전하, 모양, 코팅, 농도, 노출 시간, 실험 세포나 생물종 같은 정보를 함께 넣어야 한다.
- 2단계: 데이터 정리. 여러 논문이나 실험실에서 나온 데이터는 단위와 조건이 다르다. 그래서 같은 단위로 맞추고, 빠진 값과 이상값을 확인해야 한다.
- 3단계: 특징 만들기. 모델이 이해할 수 있도록 소재 특성을 숫자로 만든다. 예를 들어 입자 크기, zeta potential, 응집 크기, 표면 기능기, 용해도 같은 값이 특징이 된다.
- 4단계: 모델 선택. 데이터가 표 형태라면 Random Forest, Gradient Boosting, SVM 같은 모델을 쓸 수 있다. 구조 관계가 중요하면 GNN을 쓸 수 있고, 여러 모델을 합친 stacked ensemble도 가능하다.
- 5단계: 성능 평가. 학습 데이터에서만 잘 맞는지 보지 말고, 새로운 데이터에서도 맞는지 확인해야 한다. 독성 예측에서는 정확도뿐 아니라 민감도, 특이도, AUC도 같이 보는 것이 좋다.
- 6단계: 해석. 어떤 특징 때문에 독성이 높게 예측되었는지 확인해야 한다. SHAP 같은 방법을 쓰면 크기, 농도, 표면 전하 중 무엇이 영향을 줬는지 설명할 수 있다.
- 7단계: 폐쇄루프 개선. 예측 결과를 보고 새 실험을 설계하고, 그 실험 결과를 다시 데이터에 넣어 모델을 업데이트하는 방식이 중요하다.

우리 연구에서 활용 가능한 부분

- 화장품에는 자외선차단제, 색소, 전달체처럼 나노소재 또는 미세입자 성분이 포함될 수 있으므로 안전성 평가 배경으로 활용 가능하다.
- 우리 연구가 화장품 제형 단위 예측을 한다면, 단일 성분의 구조뿐 아니라 농도, 배합, 입자 특성 같은 제형 정보를 넣어야 한다는 근거가 된다.
- 농약 제형 데이터에서 화장품 데이터로 옮겨갈 때, 데이터 조건이 달라지는 문제를 domain adaptation 또는 transfer learning으로 다뤄야 한다는 설명에 쓸 수 있다.
- 모델 결과를 해석가능하게 만들어야 규제나 안전성 평가에서 설득력이 높아진다는 근거로 활용할 수 있다.

두 논문을 우리 연구에 연결하는 방법

연구 단계	AttentiveSkin에서 가져올 점	AI-Nano 리뷰에서 가져올 점
데이터 확보	여러 출처 데이터를 합치되 라벨 기준을 통일한다.	실험 조건과 소재 특성까지 함께 정리해야 한다.
라벨 설계	부식성, 자극성, 음성처럼 예측 대상을 명확히 나눈다.	독성 endpoint가 여러 개라면 endpoint별로 따로 설계한다.
모델 구축	여러 ML 모델과 분자 표현을 비교한다.	제형/나노소재 특성이 있으면 표 기반 모델, ensemble, GNN도 고려한다.
성능 평가	교차검증과 외부 검증을 함께 사용한다.	새로운 도메인에서도 맞는지 확인한다.
해석	SHAP와 attention으로 중요한 분자 부분을 본다.	중요한 제형 특성과 실험 조건을 설명한다.
화장품 적용	성분 구조 기반 피부 독성 예측에 직접 활용한다.	화장품 제형, 나노소재, 전달체 안전성 평가 논리로 활용한다.

발표용 쉬운 요약 문장

- AttentiveSkin 논문은 화학구조만으로 피부 부식성과 자극성을 예측할 수 있음을 보여준다.
- AI-Nano 리뷰 논문은 복잡한 소재나 제형의 안전성 평가는 단일 성분보다 더 많은 정보를 모델에 넣어야 한다는 점을 알려준다.
- 따라서 우리 연구는 공개 독성 데이터로 기본 예측 모델을 만들고, 화장품 제형 특성을 반영해 실제 화장품 안전성 예측으로 확장하는 방향으로 설계할 수 있다.

참고문헌

- Huang, Z.; Lou, S.; Wang, H.; Li, W.; Liu, G.; Tang, Y. (2024). AttentiveSkin: To Predict Skin Corrosion/Irritation Potentials of Chemicals via Explainable Machine Learning Methods. Chemical Research in Toxicology, 37(2), 361-373. DOI: 10.1021/acs.chemrestox.3c00332.
- Zhou, H. et al. (2026). New Frontiers in AI-Nano Converged Platforms for Intelligent Diagnostics, Therapeutics, and Safety Evaluation. Chem & Bio Engineering, 3(6), 555-584. DOI: 10.1021/cbe.5c00188.

작성 기준: ACS 논문 페이지, PubMed 메타데이터/초록, PMC 공개 본문을 확인하여 한국어 학술제 공유용으로 재구성함.