ChemExpo 기반 화장품 도메인 재검토 보고서

팀 COS · skin 트랙 · 2026-11-06

배경

"화장품 자극성 전이학습은 데이터가 없어서 못 한다"는 기존 결론을, 팀원이 EPA ChemExpo(화장품 성분·조성 공개 DB)로 다시 검토해보자고 제안했습니다. 기존에는 화장품 27종만으로 도메인갭/적용범위(AD)를 분석해 결과가 불안정했는데, ChemExpo로 더 많은 실제 화장품 데이터를 확보하면 더 안정적으로 판단할 수 있는지 ①~④ 네 단계로 확인했습니다.

① Personal care 조성 데이터 수집

팀원은 EPA 접속이 안 돼 Personal care의 일부(PUC137)만 받았었는데, 이번엔 직접 접속해 Personal care 전체 하위 카테고리(메이크업·헤어스타일링·향수·네일·구강청결 등)를 수집했습니다.

	PUC137만(팀원 1차)	Personal care 전체(이번)
고유 제품 수	2,254개	77,535개
함량(%) 공개 행 비율	1.8%	0.3%(비율은 더 낮아짐)
완전 조성 제품(성분≥5, 함량합 80~105%)	11개	103개 (공업용 5개 제외 후, 약 9배)

"완전 조성 제품"은 어떤 성분이 몇 %씩 들어있는지 레시피가 거의 다 공개된 제품을 뜻합니다(나머지는 성분 이름만 있고 비율은 비공개). 범위를 넓히니 공개 비율 자체는 더 떨어졌지만(화장품 라벨이 원래 %를 잘 안 적는 구조적 문제), 절대 개수는 늘었습니다.

정정(팀원 검토 후): PUC 분류가 72% 자동(NLP)이라 공업용 제품이 섞일 수 있다는 지적을 받아 108개 제품명을 전수 확인, 실제 공업용/비제품 5건(hastelloy w=금속합금, nitriding stop-off coating=산업 코팅제, way oil=산업 윤활유, isopropanol=완제품이 아닌 원료 자체, capote=화장품과 무관한 성분)을 찾아 제외했습니다. 최종 103개입니다.

② 성분 어휘 겹침 + 에탄올·계면활성제 분포

skin ICE 데이터의 성분(270종, CAS번호 기준)과 ①에서 모은 화장품 성분 어휘를 비교했습니다.

	PUC137 어휘(팀원 1차)	Personal care 전체 어휘(이번)
어휘 크기	1,341종	3,746종
skin ICE와 겹치는 성분	22종	36종

겹치는 성분을 가진 제형(76건)의 양성(자극성 있음)률은 18.4%인 반면, 안 가진 제형(465건, 541건 기준 통일 후)은 3.4%였습니다(Odds Ratio=6.34, $p=8.6\times10^{-6}$ — 통계적으로 매우 유의, 기존 544건 기준값과 사실상 동일). isothiazolone계·할로겐화 하이단토인계·Bronopol 등 보존제·살균제 계열이 특히 강했습니다(양성률 80~100%).

108개 완전조성 제품 중 에탄올 함유 19개(농도 1.5~80%), 계면활성제 함유로 처음 분류한 10개 중 실제 계면활성제는 4개뿐이었습니다(나머지 6개는 "sulfate"라는 단어 때문에 잘못 걸린 무기염·킬레이트제였음 — 추후 발견해 정정).

정정 1: 초기 키워드 매칭(sulfate/glutamate 등)이 황산마그네슘·황산바륨·황산나트륨·과황산칼륨(전부 무기염) 및 글루탐산 유도체 킬레이트제를 잘못 포함시켰음을 발견해 바로잡았습니다. 진짜 계면활성제는 Sodium dodecyl sulfate, Cocamidopropyl betaine, PEG-7 glycerol cocoate, SLES 계열 1종, 총 4개입니다.

정정 2(팀원 지적): Donahue 2011(에탄올 · 계면활성제 10% 기준)은 안구(eye) 전용 베이스라인입니다. 피부에 해당하는 건 Lechuga 2025이고 이건 HLB 값이 필요한데(④ 참조) 확보가 불가능하다고 이미 결론 냈습니다. 따라서 에탄올 · 계면활성제 함량 수치는 참고용일 뿐, 피부 베이스라인 재시도 근거로는 쓰지 않습니다.

③ 도메인갭/적용범위(AD) 재분석

skin production 모델(RF)이 실제로 쓰는 feature 공간에서, 화장품이 ICE 학습데이터의 "적용범위" 안에 있는지를 표준 QSAR 방법(최근접이웃 거리)으로 재계산했습니다.

정정(팀원 지적, 중요): 최초 보고에서 "63.3%로 수렴했다"고 썼으나, 이는 한 가지 방법(95th percentile, 1-NN)만으로 계산한 값을 과대해석한 것이었습니다. 아래 재검증 결과로 이 주장을 철회합니다.

	화장품 27종(기존)	화장품 103종(이번, 9가지 방법)
적용범위(AD) 안쪽 비율	집계 방식에 따라 0~88.9%(폭 88.9%p)	44.9~100%(폭 55.1%p)

k=1/3/5 - 최근접이웃 × 90/95/99th percentile 기준, 9가지 조합을 전부 계산했습니다. 폭이 27종 때보다는 좁아졌지만(88.9%p→55.1%p), "하나의 안정적인 숫자로 수렴했다"고 말할 수준은 아닙니다 — 방법에 따라 여전히 거의 두 배 차이가 납니다.

제외된 제품(13개, 구조 계산 불가)의 성분을 직접 분류한 결과, 무작위 결손이 아니었습니다:
UVCB(광물유 · 왁스 · 라놀린) 18회, 식물추출물 7회, 폴리머 6회, 무기물 · 금속 5회 —
선크림 · 립글로스 · 헤어왁스 · 보습크림류가 체계적으로 빠지고 있었습니다. (팀원이 제시한 구체적 가설인 "계면활성제가 빠진다"는 직접 확인 결과 해당 없음 — 계면활성제는 제외 목록에 0건이었습니다. 편향의 방향은 달랐지만, 편향이 실재한다는 지적 자체는 맞았습니다.)

정정된 결론: 화장품 108→103종 확장은 AD 추정의 불안정성을 완화했을 뿐 해소하지 못했고, 그 추정치도 UVCB · 추출물 비중이 큰 제품이 체계적으로 빠진 편향 표본 위에서 계산된 것입니다. "구조적으로 비슷한 화장품을 알아보는가"에 대한 잠정적 신호 정도로만 해석해야 하며, 실제 화장품 자극성 예측 성능을 검증한 것이 아닙니다(화장품 쪽엔 자극성 라벨이 없어 정확도 계산 불가). "화장품 외부검증 수행 안 함" 원칙은 그대로 유지됩니다.

④ HLB 테이블 확보 여부 판단

skin용 베이스라인 논문(Lechuga 2025)은 계면활성제의 HLB(친수성 - 친유성 균형) 값이 필요합니다. 확보 가능성을 확인했습니다.

- ChemExpo 메타데이터에 HLB 컬럼 없음
- PubChem에도 HLB를 구조화된 값으로 조회하는 기능 없음(직접 테스트로 확인)
- HLB 값은 제조사 기술자료(Croda, BASF 등) · 계면활성제 전문서적에만 있어 API로 못 긁어옴 — 성분별 수동 문헌조사 필요
- 그런데 ②번 정정 결과 실제 계면활성제가 4개뿐이라, 수동으로 다 찾아도 베이스라인을 만들 표본이 안 됨

판단: HLB 테이블은 확보하지 않기로 함.

종합 결론

화장품 27종 대신 ChemExpo 103종으로 교체하자 ②성분 겹침(22→36종, OR 6.34 유의)은 더 신뢰할 수 있는 결과로 바뀌었습니다. ③적용범위 추정은 불안정성이 완화됐을 뿐 해소되지는 않았고(폭 88.9%p→55.1%p), 그 추정도 편향된 표본(UVCB · 추출물 제품 체계적 제외) 위에서 나온 것이라는 한계가 남습니다. ④HLB처럼 화장품 쪽 데이터 자체가 구조적으로 부족한 지점도 그대로입니다.

이 보고서의 1차 버전은 팀원 검토에서 ①공업용 오분류 미확인, ②Donahue(안구전용) 서술 오류, ③"수렴" 과대해석이라는 세 가지 지적을 받아 전부 재검증 후 정정했습니다. 보존제 · 살균제 계열

성분이 skin 자극성과 강하게 연관된다는 발견(OR=6.34~17.93)은 재검증 후에도 유지되는 유의미한 결과지만, 화장품에 대한 실제 자극성 라벨은 여전히 없어 화장품 외부검증을 수행했다고 주장하지는 않습니다.

근거 노트북: skin irritation/chemexpo/ (skin_chemexpo_overlap_demo.ipynb, skin_chemexpo_domain_gap_demo.ipynb, skin_chemexpo_v2_corrected.ipynb=팀원 피드백 재검증판) · 데이터: ChemExpo_personal_care_full_composition_108.csv · 세팅/진행상황.md 2026-11-06(1~7차) 기록