ChemExpo 기반 화장품 도메인 재검토 보고서

팀 COS · skin 트랙 · 2026-11-06

배경

"화장품 자극성 전이학습은 데이터가 없어서 못 한다"는 기존 결론을, 팀원이 EPA ChemExpo(화장품 성분·조성 공개 DB)로 다시 검토해보자고 제안했습니다. 기존에는 화장품 27종만으로 도메인갭/적용범위(AD)를 분석해 결과가 불안정했는데, ChemExpo로 더 많은 실제 화장품 데이터를 확보하면 더 안정적으로 판단할 수 있는지 ①~④ 네 단계로 확인했습니다.

① Personal care 조성 데이터 수집

팀원은 EPA 접속이 안 돼 Personal care의 일부(PUC137)만 받았었는데, 이번엔 직접 접속해 Personal care 전체 하위 카테고리(메이크업·헤어스타일링·향수·네일·구강청결 등)를 수집했습니다.

	PUC137만(팀원 1차)	Personal care 전체(이번)
고유 제품 수	2,254개	77,535개
함량(%) 공개 행 비율	1.8%	0.3%(비율은 더 낮아짐)
완전 조성 제품(성분≥5, 함량합 80~105%)	11개	108개 (10배)

"완전 조성 제품"은 어떤 성분이 몇 %씩 들어있는지 레시피가 거의 다 공개된 제품을 뜻합니다(나머지는 성분 이름만 있고 비율은 비공개). 범위를 넓히니 공개 비율 자체는 더 떨어졌지만(화장품 라벨이 원래 %를 잘 안 적는 구조적 문제), 절대 개수는 10배 늘었습니다.

② 성분 어휘 겹침 + 에탄올·계면활성제 분포

skin ICE 데이터의 성분(270종, CAS번호 기준)과 ①에서 모은 화장품 성분 어휘를 비교했습니다.

	PUC137 어휘(팀원 1차)	Personal care 전체 어휘(이번)
어휘 크기	1,341종	3,746종
skin ICE와 겹치는 성분	22종	36종

겹치는 성분을 가진 제형(76건)의 양성(자극성 있음)률은 18.4%인 반면, 안 가진 제형(468건)은 3.4%였습니다 (Odds Ratio=6.38, $p=8.0\times10^{-6}$ — 통계적으로 매우 유의). isothiazolone계·할로겐화 하이단토인계·Bronopol 등 보존제·살균제 계열이 특히 강했습니다(양성률 80~100%).

108개 완전조성 제품 중 에탄올 함유 19개(농도 1.5~80%), 계면활성제 함유로 처음 분류한 10개 중 실제 계면활성제는 4개뿐이었습니다(나머지 6개는 "sulfate"라는 단어 때문에 잘못 걸린 무기염·킬레이트제였음 — 추후 발견해 정정).

정정: 초기 키워드 매칭(sulfate/glutamate 등)이 황산마그네슘·황산바륨·황산나트륨·과황산칼륨(전부 무기염) 및 글루탐산 유도체 킬레이트제를 잘못 포함시켰음을 발견해 바로잡았습니다. 진짜 계면활성제는 Sodium dodecyl sulfate, Cocamidopropyl betaine, PEG-7 glycerol cocoate, SLES 계열 1종, 총 4개입니다.

③ 도메인갭/적용범위(AD) 재분석

skin production 모델(RF)이 실제로 쓰는 feature 공간에서, 화장품이 ICE 학습데이터의 "적용범위" 안에 있는지를 표준 QSAR 방법(최근접이웃 거리)으로 재계산했습니다.

	화장품 27종(기존)	화장품 108종(이번)
적용범위(AD) 안쪽 비율	집계 방식에 따라 0~24/27로 요동	63.3% (57/90, 안정적 단일값)

AD 안쪽(모델이 "알아볼 수 있는" 화장품): 선크림 스프레이, 토너, 네일 제품, 에어로졸류. AD 바깥쪽(낯선 화장품): 버블배스 · 폼클렌저 · 손비누 등 계면활성제 위주 세정제. ICE 데이터가 농약 제형 기반이라, 세정제 계열과는 화학적 특성 차이가 크다는 것과 일관된 결과입니다.

주의: 이건 "구조적으로 비슷한 화장품을 알아보는가"를 본 것이지, 실제 화장품 자극성 예측 성능을 검증한 게 아닙니다(화장품 쪽엔 자극성 라벨이 없어 정확도 계산 불가). "화장품 외부검증 수행 안 함" 원칙은 그대로 유지됩니다.

④ HLB 테이블 확보 여부 판단

skin용 베이스라인 논문(Lechuga 2025)은 계면활성제의 HLB(친수성 - 친유성 균형) 값이 필요합니다. 확보 가능성을 확인했습니다.

- ChemExpo 메타데이터에 HLB 컬럼 없음
- PubChem에도 HLB를 구조화된 값으로 조회하는 기능 없음(직접 테스트로 확인)
- HLB 값은 제조사 기술자료(Croda, BASF 등) · 계면활성제 전문서적에만 있어 API로 못 긁어옴 — 성분별 수동 문헌조사 필요
- 그런데 ②번 정정 결과 실제 계면활성제가 4개뿐이라, 수동으로 다 찾아도 베이스라인을 만들 표본이 안 됨

판단: HLB 테이블은 확보하지 않기로 함.

종합 결론

화장품 27종 대신 ChemExpo 108종으로 교체하자 ②성분 겹침(22→36종)과 ③적용범위 추정(불안정→63.3% 안정)이 모두 더 신뢰할 수 있는 결과로 바뀌었습니다. 다만 ④HLB처럼 화장품 쪽 데이터 자체가 구조적으로 부족한 지점은 여전히 한계로 남습니다. 보존제 · 살균제 계열 성분이 skin 자극성과 강하게 연관된다는 발견(OR=6.38 ~ 17.93)은 흥미롭지만, 여전히 화장품에 대한 실제 자극성 라벨이 없어 화장품 외부검증을 수행했다고 주장하지는 않습니다.

근거 노트북: skin irritation/chemexpo/ (skin_chemexpo_overlap_demo.ipynb, skin_chemexpo_domain_gap_demo.ipynb) · 데이터: ChemExpo_personal_care_full_composition_108.csv · 세팅/진행상황.md 2026 - 11 - 06 기록