eye 모델 실험 정리 (11/07 ~ 11/08)

작성 2026-11-08 02:13

① 모델링 기법은 전부 실패 - 앙상블·순서형·표현결합·확률보정 모두 seed 변동 이내

② 원인 발견 - 평가 606행 중 218행이 "같은 입력, 다른 정답" (단일성분 농도 약분)

③ 농도 피처 추가로 라벨 B에서 처음으로 seed 변동을 넘긴 개선 (+0.030, 10칸 중 9칸)

작업 목록

항목	일자	내용	상태
EPA+GHS 결과 감사	11/07	서명 2,521개 검증, 누수 0, GHS 부진 원인 규명	완료
1차 실험 00~06	11/07	진단·천장·앙상블·그룹화·순서형·표현 6종	완료
2차 실험 07~10	11/07~08	표현결합·확률보정·교차앙상블 (09는 중단)	완료
데이터 결함 발견	11/07	농도 소실 - 218행 구분 불가	완료
11번 농도 복원	11/08	방안 1 채택, 방안 2 기각	완료
skin 팀 보고 검증	11/07~08	결함 실재 확인, 영향 규모 재계산	완료

모든 수치는 축소 격자(후보 20개 중 6개) 내부 교차검증 결과이며, 발표된 production 수치와 직접 비교하면 안 됩니다. 중복 판정은 feature 벡터를 소수 6자리로 반올림한 뒤 행 단위 해시로 합니다(skin 팀과 동일 기준).

1차 실험 00~06 - 무엇을 해도 움직이지 않았다

판단 기준: seed만 바꿨을 때의 MCC 변동 ±0.024 (실험 03에서 측정)

#	실험	결과 (ΔMCC)	판정
00	데이터 진단	673행 중 고유 벡터 444개, 중복 102그룹 331행	-
01	이론적 천장	중복 라벨충돌로 상한 A 0.861 / B 0.795	-
02	앙상블 (저장 OOF)	A -0.052, B +0.004	**효과 없음**
03	그룹화 수정	A +0.001, B -0.016 (동시에 seed 변동 0.024 측정)	**효과 없음**
04	순서형 (4등급 누적)	A +0.011 (14/15), B +0.005 (7/15)	모델별 편차
05	최악성분 pooling	A -0.014, B +0.012	**효과 없음**
06	특징 집합 재조합	A 물성22+fp1024 lr 0.335, B desc만 xgb 0.232	**소폭**

여기서 얻은 가장 중요한 것 - 판단 기준

실험 03에서 분할 seed만 바꿔가며 같은 모델을 돌렸더니 MCC가 ±0.024 범위로 흔들렸습니다. 지금까지 모델 순위를 매길 때 쓰던 차이들 대부분이 이 범위 안이었습니다. 이후 모든 판단에 이 값을 기준선으로 썼습니다. 0.024보다 작은 차이는 효과로 부르지 않습니다.

01 천장이 알려준 것

같은 입력에 다른 정답이 붙은 행들은 어떤 모델도 둘 다 맞힐 수 없습니다. 그 불가피한 오답을 빼고 계산한 상한이 A 0.861, B 0.795입니다. 현재 실측이 0.33 수준이므로 '모델이 한계에 도달했다'는 설명은 성립하지 않습니다. 여유가 많은데 못 올라가고 있다는 뜻이고, 이것이 2차 실험의 출발점이 되었습니다.

2차 실험 07~10 - 역시 움직이지 않았다

#	실험	결과	판정
07	표현 결합 (농도가중+최악성분)	A +0.014, B +0.024	잡음 턱걸이
08	확률 보정 (Platt / Isotonic)	±0.003	기각
09	다른 지문 계열 6종	작업 360개 중 60개에서 중단	중단
10	순서형 x 이진 교차 앙상블	최고 앙상블이 최고 단일을 이긴 횟수 2/6	기각

08이 알려준 것 - 임계값 정책이 이미 보정 역할을 하고 있다

Platt 보정 결과가 보정 없음과 소수점 3자리까지 같았습니다. 우연이 아닙니다. Platt은 점수 순서를 바꾸지 않는 단조 변환이고, 저희는 inner OOF에서 임계값을 다시 고르기 때문에 그 변환을 그대로 흡수합니다. MCC가 목표라면 보정할 이유가 없습니다.

10의 부산물 - 순서형 LR이 라벨 B에서 크게 앞선다

	순서형 LR - 이진 LR (ΔMCC)	판정
라벨 A	-0.001	변동 이내
라벨 B	**+0.087**	**★ seed 변동 초과**

라벨 B의 경계는 등급 3과 4 사이입니다. 이진 LR은 "3 이하인가"만 배우는데, 순서형은 등급 4개를 모두 맞히도록 배운 뒤 누적확률로 경계를 만듭니다. 다만 LR에만 해당합니다 - rf는 -0.048, et는 -0.032로 오히려 나빠집니다.

앙상블은 점수를 못 올려도 흔들림은 줄인다

	단일 모델 seed 변동	앙상블 seed 변동
라벨 A	0.051	**0.039**
라벨 B	0.053	**0.030**

원인 발견 - 농도가 사라지고 있었다

평가 606행 중 218행이 완전히 같은 입력에 다른 정답

모델링 기법이 전부 실패하자 입력을 의심했습니다. feature 행렬을 행 단위로 해시해서 세어 봤더니, 평가 대상 606행 가운데 218행(36.0%)이 "2,265차원이 전부 동일한데 정답만 다른" 상태였습니다.

원인 - 단일성분에서 가중치가 약분된다

$$\frac{p \cdot \mathbf{v}}{p} = \mathbf{v}$$

weight_mode = pct_active_ingredient, 즉 농도 가중 평균인데 성분이 하나면 분자와 분모의 농도가 약분됩니다. 충돌 218행 중 98.2%가 단일성분입니다.

실제 사례 - CASRN 82657-04-3

농도	정답
0.05%	등급 4
0.06%	등급 3
0.083%	등급 4
0.2%	등급 4
25.1%	등급 4
98%	등급 3

단일성분 19개 제형이 0.05%에서 98%까지 걸쳐 있는데 feature 벡터가 전부 동일합니다. 두 끝이 모델에게 똑같은 입력입니다.

더 중요한 것은, 농도 값이 CSV에 이미 있다는 점입니다. known_pct 컬럼에 10, 98, 0.069가 그대로 들어 있는데 feature 열(fp_, desc_)이 아니라서 모델에 전달되지 않았을 뿐입니다.

2·3부가 전부 제자리였던 이유

> **입력에 없는 정보를 모델링 기법으로 만들어낼 수는 없습니다.**

입력	라벨 A 천장 MCC	라벨 B 천장 MCC	불가피 오답
현재 fp+desc 2,265열	**0.840**	**0.787**	**29행 / 62행**
+ known_pct	**0.984**	**0.982**	**3행 / 5행**

실험 11 - 농도 복원

방안 1(농도 피처 추가)과 방안 2(희석 스케일링)를 실제로 측정

학습 전 - 중복이 실제로 깨지는가

팔	완전중복 행	라벨충돌 행	해소율
① 기준	331행	**221행**	0%
② 농도 피처 추가	70행	**18행**	**92%**
③ 희석 스케일링	78행	**18행**	**92%**
④ 농도 피처 + 희석	68행	**18행**	**92%**

221행에서 18행으로, 92%가 해소됩니다. 세 방안이 전부 18행으로 같습니다. 남은 18행은 농도까지 같은데 정답이 다릅니다.

학습 결과 - 기준 대비 짝지은 평균 (라벨당 5모델 x 2seed = 10칸)

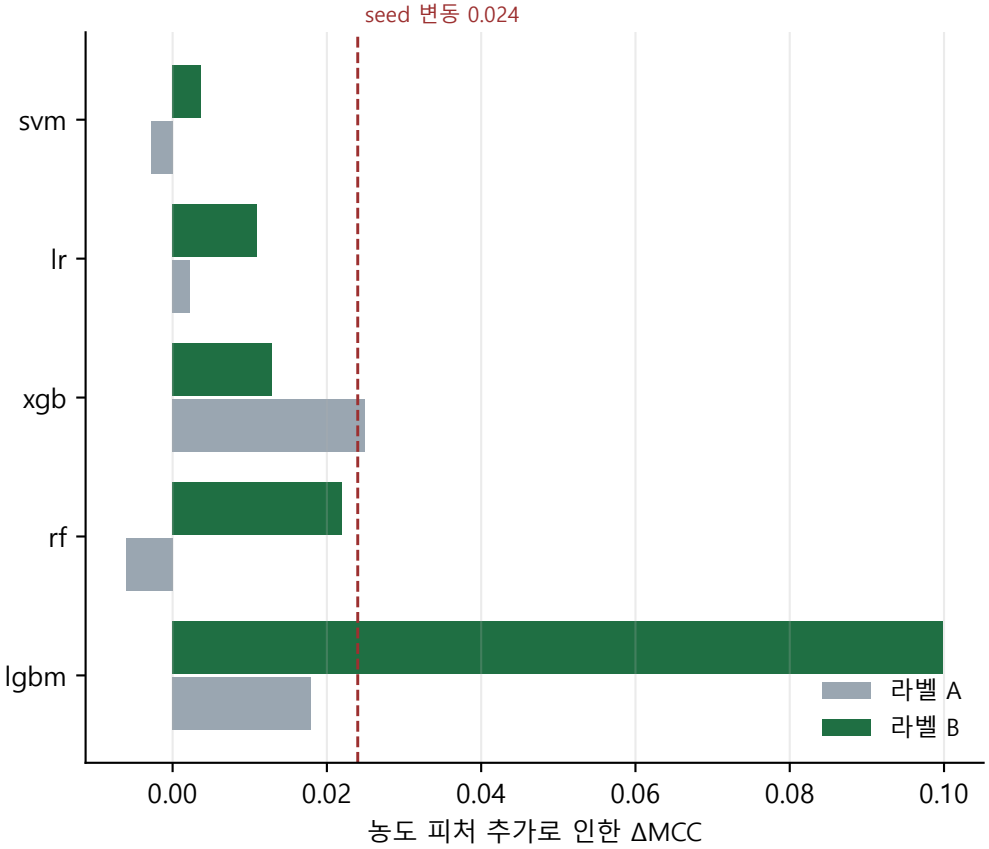
팔	라벨 A ΔMCC	라벨 B ΔMCC
② 농도 피처 추가	+0.007 (5/10)	**+0.030 ★ (9/10)**
③ 희석 스케일링	**-0.041 ★ (4/10)**	**+0.035 ★ (7/10)**
④ 농도 피처 + 희석	**-0.039 ★ (4/10)**	**+0.038 ★ (8/10)**

판정

	판정	근거
방안 1 농도 피처	**채택**	B에서 seed 변동 초과, A에 무해, fold 변동 감소
방안 2 희석 스케일링	**기각**	A에서 선형 모델 붕괴 (lr 0.329 -> 0.133)
방안 1+2	**기각**	방안 1 대비 이득 없음 (+0.008)

부수 효과 - fold 변동도 줄었습니다. A 0.120 -> 0.106, B 0.101 -> 0.085. 모순된 입력이 줄면 fold마다 다른 답을 배울 일도 줄어듭니다.

실험 11 - 어느 모델이 농도를 쓰는가



트리 계열이 농도를 가져갑니다

농도와 등급의 관계가 단조롭지 않습니다. 같은 물질이 25.1%에서 등급 4인데 98%에서 등급 3입니다. 선형 모델은 이런 관계를 거의 쓰지 못하고, 분기로 구간을 나눌 수 있는 트리가 가져갑니다. 라벨 B의 lgbm이 0.141에서 0.241로 올랐습니다.

라벨 A에서 효과가 없는 이유

라벨 A의 경계는 등급 2와 3 사이인데, 충돌 행의 등급은 대부분 3과 4입니다. 충돌이 B의 경계에 몰려 있어서 A는 애초에 이 문제의 영향을 덜 받고 있었습니다.

라벨별 최고

	기준 최고	11번 최고	차
라벨 A	0.329	② 농도 피처 추가 lr 0.331	+0.002
라벨 B	0.237	**④ 농도 피처 + 희석 lgbm 0.264**	**+0.027**

주의 - 라벨 B 최고 0.264는 ④(둘 다)에서 나왔지만, ④는 방안 1 대비 평균 +0.008로 잡음 수준이고 10칸 중 한 칸입니다. 여러 조합 중 최고를 사후에 고르면 낙관적으로 나옵니다. 안전한 선택은 ② 단독입니다.

skin 팀 보고 검증

production CSV를 직접 열어 보고된 수치를 재계산했습니다

결함은 실재합니다

항목	값	판정
원본 544행 중 comp_group_id == formulation_id	97.2%	보고와 일치
comp_group_id 값 형태	MIX1	제품 일련번호
composition_key / split_group_id 컬럼	둘 다 없음	eye에는 둘 다 있음
comp_group_id가 쪼갠 중복행	83그룹 276행 (41.7%)	보고와 일치
union-find 그룹 수	641 -> 463	보고와 일치

그룹 식별자가 조성이 아니라 제품명을 따르고 있었습니다. 같은 조성을 다른 제품명으로 등록한 쌍둥이 제형이 서로 다른 그룹으로 취급되어, train과 test 양쪽에 동시에 들어갈 수 있었습니다. 보고된 수치가 전부 재현됩니다.

실제로 fold를 가로지르는 행 - 직접 돌려서 측정

	가로지르는 행 (seed 3개 평균)	비율
skin	259행	39.1%
eye	62행	9.2%

eye가 훨씬 적은 것은 조성 해시와 split_group_id가 이미 들어가 있어서 이 경로가 대부분 막혀 있기 때문입니다. skin은 그 두 컬럼이 없습니다.

다만 라벨이 서로 다른 중복행은 41행뿐이라 모순된 학습 신호는 아닙니다. 점수가 부풀려지는 쪽입니다.

skin 수정안에서 점검할 곳

	점검할 곳	결과
①	구조 해결 성분이 0개인 행	comp_sig가 빈 문자열이 되어 그런 행이 전부 한 그룹으로 묶임
②	미해결 성분 무시로 인한 과병합	해결 성분은 같고 미해결 성분만 다른 제형이 같은 해시를 받음
③	농도 소수 1자리 반올림	40.04와 40.0이 합쳐짐

산출물과 한계

산출물

파일	내용
eye_all_experiments.ipynb	81셀 · 1부 GJC + 2~4부 Claude · 실행 오류 0
claude/run_experiments.py	1차 실험 00~06
claude/run_advanced.py	2차 실험 07~10
claude/run_concentration.py	11번 농도 복원
claude/results/*.json	원시 결과 00~11
claude/results/10_oof_pool.json	fold별 OOF 점수 - 추가 앙상블을 재학습 없이 시도 가능
claude/그룹분할_농도소실_판단보고서.pdf	그룹 분할·농도 소실 상세 분석 8쪽

한계

- 모든 실험이 축소 격자(후보 20개 중 6개)입니다. 발표된 production 수치와 절대값을 비교하면 안 됩니다. 비교는 같은 프로토콜 안에서만 유효합니다.
- 실험 03의 ΔMCC -0.008은 정확 비트 해시로 묶은 분할에서 측정했습니다. 소수 6자리 기준이면 묶을 행이 24행에서 77행으로 늘어나므로 하한으로 읽어야 합니다.
- 11번은 seed 2개이고 et를 제외했습니다(2·3부 일부는 seed 3개, 6모델). 짝지은 비교로 보완했지만 신뢰구간이 아니며 2·3부 표와 나란히 두면 안 됩니다.
- 09(다른 지문 계열 6종)는 606행 한정 설계에 2시간이 더 필요해 중단했습니다. 코드는 남아 있어 SKIP 목록에서 빼면 다시 돌릴 수 있습니다.
- 전부 내부 교차검증이며 외부 독립 데이터 검증이 아닙니다.