[외부검증/일반화 테스트] 계면활성제 Mixture 자극성 데이터 확보 보고

COS팀 · 학술제 · 2026-11-07 · 작성: 김서율 세션

0. 용어 확인

세션_핸드오프_2026-11-07.md 5절 규칙에 따라 화장품 관련 적용은 "전이학습"이 아니라 "외부검증/일반화 테스트"로 표기함. 아래 내용은 모델 파라미터를 화장품 데이터로 재학습하는 작업이 아니라, production 모델(또는 그 표현)이 다른 도메인에서도 쓸 만한지 검증·보강하는 작업임.

1. 배경

- 기존 화장품 mixture 데이터 탐색은 EPA/GHS 라벨 기준으로 한정했다가 대부분 실패(COSMOS DB 폐기, SCCS/식약처/상업제품 논문 전수조사 세션 한도로 대부분 실패)
- 기준을 완화함 — EPA/GHS가 아니어도, 단일성분이 아니라 mixture 기준이어도, 실험데이터이기만 하면 특정 기준으로 binary label 변환만 가능하면 채택
- 이 기준으로 재탐색한 결과 Lechuga et al. 2025(ACS Omega) 계면활성제 mixture Zein 자극성 데이터 확보

2. 확보한 데이터

① 출처

- Lechuga et al., ACS Omega 10(46):55868–55878 (2025)
- Zenodo DOI 10.5281/zenodo.15800001 (CC-BY-4.0, 무료 공개, 2025-07-03)
- 계면활성제 20종 + 이들의 2성분 mixture, 농도 0.5/1/2%, 이온성 조합 A(Anionic)/NI(Nonionic)/AA/ANI/NINI, HLB1·HLB2·HLB_compost(기하평균) 포함

② 측정값 → binary label 변환 근거

- 측정값: Zein Number(ZN) — 계면활성제가 zein 단백질을 변성/용해시키는 정도를 재는 in vitro 피부자극 대체시험(Draize 아님)
- ECVAM DB-ALM Protocol n°26(The Zein Test, 1991, 공식 규제기관 문서)이 3단계 공식 cutoff 제공: Non-irritant(ZN<200) / Moderate(200–400) / Strong(>400)
- → ZN≥200 = 1(자극), ZN<200 = 0(비자극)으로 변환(추측 아니라 공인 cutoff 사용)

③ 처리 결과 파일

파일	내용
cosmetic_validation/lechuga2025_surfactant_mixture_zein.csv	205행(ZN 결측 72행 제외) · label 0:149 / 1:56(양성비율 약 27%, 현 production보다 균형적) · mixture_type=binary_mixture 117행 / single 88행
cosmetic_validation/Lechuga2025_surfactant_zein_dataset.xlsx	원본 보관(재가공 가능하도록)

3. 한계 (발표/보고 시 반드시 같이 언급할 것)

Zein test ≠ Draize

- in vitro 대체시험이라 실제 Draize/EPA 등급 예측력 향상을 바로 주장할 수 없음 — "표현/보조정보로서 도움이 되는지"만 평가 가능

성분 구조(SMILES/CAS) 대부분 미해결

- 성분명이 INCI명(Laureth-11 Carboxylic Acid, Glycereth-7 Cocoate 등)으로 대부분 UVCB(비균질 다성분) 물질 — 지금 단계에서 구조 feature 적용 불가, HLB·이온성 등 비구조 feature만 사용 가능

4. 적용(외부검증) 시 필요한 절차

pretraining/ 폴더에 이미 ChemBERTa 기반 mixture 인코딩 인프라(protocol.json 기준)가 있어 그 틀에 맞추는 것을 전제로 함.

단계	내용	비고
1	구조 해결(선행 블로커) — 20종 중 단일구조로 환원 가능한 성분만 SMILES 확보	UVCB는 미해결(unresolved) 유지, 추측 금지
2	mixture_predictor.py 입력 스키마 변환 — amount_pct(함량%)·structure_status 등	2성분 비율(proportion)→절대% 환산 근거는 원문 재확인 필요
3	라벨을 skin_epa와 분리된 별도 엔드포인트(예: skin_zein)로 유지	Draize 예측력 주장과 혼동 방지
4	적용 방식 택1 — (A)MLM 코퍼스 확장 (B)보조 head/멀티태스크 (C)warm-start	아래 5절 비교표 참조
5	검증 — group-aware split, scaffold split, train-only imputer, 결과 보기 전 설계 동결	protocol.json 기존 원칙 그대로 적용

5. 적용 방식 비교

방식	내용	장단점
(A) MLM 코퍼스 확장	Lechuga 성분 SMILES를 추가 MLM 코퍼스에 합쳐 pretraining/best 재학습	가장 안전, skin_epa/eye_epa 안 건드림 / 효과는 작을 수 있음
(B) 보조 head(권장)	같은 pooled 임베딩 위에 skin_zein 전용 head만 새로 학습	구조상 가장 깔끔, 기존 head 영향 없음
(C) warm-start	Zein 데이터로 먼저 학습 후 그 가중치를 skin_epa 분류기 초기값으로	표본이 적어 과적합 위험 큼 / RandomForest(skin_rf)엔 적용 불가

6. 팀 결정이 필요한 사항

- 적용 방식 (A)/(B)/(C) 중 무엇으로 갈지
- 20종 성분 SMILES 수작업 확인을 누가/언제 할지(대부분 UVCB라 시간이 걸림)
- 2성분 mixture의 proportion("1-1" 등) → 절대 함량% 환산 규칙을 논문 원문에서 재확인할지
- 발표자료에 이 작업을 "외부검증/일반화 테스트"로 표기하는 것에 이견 없는지

참고 — 세팅/진행상황.md 14~15차 항목에 상세 기록됨