[Skin Irritation] RF production 공식 재검증 보고서

COS팀 · 학술제 · 2026-11-07 · 대상: modeling/skin_rf (RandomForest, wmean 집계, 라벨 B)

1. 배경 — 오늘 적용된 두 가지 수정

- comp_group_id 누수 수정: 원본 544건의 comp_group_id 중 97.2%가 formulation_id를 그대로 복사한 값이라 train/test 그룹 분리가 사실상 작동하지 않고 있었음(83개 그룹·276행이 특징벡터는 동일한데 서로 다른 그룹으로 찢어져 있었음). 조성 시그니처 해시 ∪ wmean 특징벡터 해시(union-find)로 재계산 → 635개 → 463개 그룹.
- binary_label A → B 전환: 팀 결정에 따라 production 타겟 정의를 라벨 A(양성 37/662)에서 라벨 B(양성 122/662, 결측 제외 후 120/659)로 변경.
- 이 두 수정은 모델을 더 똑똑하게 만든 것이 아니라, 성능 비교 결과를 신뢰할 수 있게 만든 것임 — 아래 수치 변화는 "정확도가 올랐다/내렸다"가 아니라 "더 믿을 수 있는 숫자로 교체됐다"로 읽어야 함.

2. 재검증 방법

- 스크립트: skin irritation/rf_feature_compare/rf_production_recheck.py (수정 없이 그대로 재실행 — binary_label/comp_group_id를 skin_vectorized.csv에서 그때그때 동적으로 읽으므로 오늘 수정이 자동 반영됨)
- 모델: RandomForestClassifier(class_weight=balanced) — 현재 production과 동일 설정(wmean 집계, nz20 특징필터)
- 분할: comp_group_id 기준 group 5-fold, 20회 반복(seed 0~19) — 매 반복 fold별 검증셋에서 |Sensitivity-Specificity| 최소가 되는 threshold를 고르고(0.5 고정이 아님), out-of-fold 예측으로 집계
- 사용 데이터: 659건(binary_label 분포 0=539 / 1=120), 2,266차원 특징

3. 결과 — 수정 전(11-06, 라벨A) vs 수정 후(11-07, 라벨B)

두 줄은 "같은 반복 group 5-fold + 균형점 threshold" 방법으로 측정된 값이라 서로 비교 가능함. 다만 라벨 정의(A→B)와 그룹핑 수정이 동시에 들어간 비교라 두 변화를 분리해서 보여주지는 못함.

구분	Sensitivity	Specificity	격차(|Sens-Spec|)	MCC	ROC-AUC	threshold
11-06 (라벨A, comp_group_id 수정 전)	0.703±0.038	0.700±0.026	0.027±0.022	0.199±0.031	0.741±0.015	0.044±0.005
11-07 (라벨B, comp_group_id 수정 후)	0.636±0.022	0.642±0.021	0.014±0.008	0.218±0.033	0.701±0.016	0.200±0.007

4. 해석

수정 후에도 production RandomForest(wmean 집계)는 균형점 threshold를 쓰면 Sensitivity/Specificity가 거의 동률(0.636 vs 0.642, 격차 1.4%p)로 상당히 안정적임.

- MCC는 오히려 소폭 상승(0.199→0.218), 격차는 더 줄어듦(2.7%p→1.4%p) — "수정했더니 성능이 나빠졌다"는 아님.
- Sensitivity/Specificity 절대값과 ROC-AUC는 소폭 하락(0.70→0.64대, 0.741→0.701) — 양성 정의가 더 느슨한 쪽(A→B)으로 바뀌면서 경계가 애매한 사례가 늘어난 영향 + fold 구성이 바뀐 영향이 섞여 있음. comp_group_id 수정만의 순수 효과는 아님.
- 핵심: threshold를 0.5로 고정하지 않고 제대로 튜닝하면 라벨 B·수정된 그룹핑에서도 RF가 민감도·특이도 어느 한쪽에 치우치지 않는다는 것이 반복 5-fold로 확인됨.

5. 이번 재검증이 다루지 않은 것 (중요)

이 보고서는 "현재 production 설정(RandomForest + wmean)"의 공식 재검증일 뿐, 별도 노트북(skin_final_combined_eval.ipynb)에서 나온 "라벨 B는 ExtraTrees+top 조합이 더 낫다"는 결론을 같은 반복 5-fold 방식으로 재확인한 것은 아직 아님.

- rf_production_recheck.py는 모델을 RandomForest 한 가지로, 집계방식을 wmean 한 가지로 고정해서만 테스트하는 스크립트임 — ExtraTrees·top 조합을 같은 반복 group 5-fold 방식으로 넣어 비교하려면 별도 스크립트 작성이 필요함(단순 재실행이 아님).
- 따라서 "ExtraTrees+top으로 실제 전환할지"는 이번 재검증과 별개로 아직 열려 있는 결정임. 지금 결과는 "현재 production(RF+wmean)도 라벨B·수정된 데이터에서 꽤 균형 잡혀 있다"는 사실만 추가한 것.