RF vs 신경망(NN) 모델 비교 보고서

팀 COS · skin 트랙 production 모델 선정 · 2026-11-05

배경

같은 skin 트랙인데 저(NN · 신경망)와 팀원(RF · RandomForest)이 서로 다른 모델을 쓰고 있다는 지적을 받아, 완전히 동일한 데이터 · 분할 · feature로 두 모델을 정면 비교했습니다. 과정에서 두 번 결론을 뒤집었고, 그 과정 자체가 중요한 방법론 교훈이라 함께 기록합니다.

1차 비교 — 틀린 결론: threshold 0.5 고정

처음엔 두 모델에 똑같이 threshold 0.5를 적용해 비교했습니다.

	NN	RF
Sensitivity	0.610	0.177
Specificity	0.727	0.986
격차	0.127	0.809
MCC	0.170	0.248
ROC-AUC	0.722	0.721

RF의 Sensitivity가 0.177로 극히 낮아 "NN이 낫다"고 결론 내렸으나, 이는 잘못된 비교였습니다. RF와 NN은 확률을 뱉는 방식(보정)이 다릅니다 — 양성이 5.5%뿐이라 RF의 확률은 낮은 쪽에 몰리고, class-weighted loss를 쓰는 NN의 확률은 더 퍼져 있습니다. 같은 0.5라도 두 모델에서 의미가 다른데, 이를 무시하고 비교한 것이 문제였습니다(팀원이 지적).

2차 비교 — 각 모델의 균형점(balance point) threshold에서 비교

각 모델에서 Sensitivity와 Specificity 차이가 가장 작아지는 지점(threshold)을 찾아 그 지점끼리 비교했습니다. 반복 횟수를 늘릴수록 결론이 더 뚜렷해졌습니다.

반복 10회 — 거의 동률로 보임

	NN	RF
threshold	0.440±0.038	0.035±0.005
Sensitivity	0.660±0.033	0.670±0.043
Specificity	0.666±0.031	0.680±0.027
MCC	0.157±0.033	0.170±0.032
ROC-AUC	0.722±0.030	0.721±0.027

반복 30회(가장 신뢰할 수 있는 수치) — RF가 우세

	NN	RF

threshold	0.415±0.062	0.035±0.006
Sensitivity	0.656±0.036	0.684±0.038
Specificity	0.659±0.034	0.684±0.025
격차	0.009±0.009	0.027±0.022
MCC	0.151±0.035	0.179±0.029
ROC - AUC	0.714±0.030	0.729±0.019

짝지은 비교(같은 분할끼리): Sensitivity(t=+2.98) · MCC(t=+3.28) · ROC - AUC(t=+2.48) 전부 RF가 통계적으로 유의하게 높음. NN은 격차(0.009 vs 0.027)만 더 작음 — 다만 둘 다 절대값이 작아 실질적 차이는 크지 않음. 또한 RF의 최적 threshold(0.035±0.006)가 NN(0.415±0.062)보다 10배 이상 일관됨.

10회에서는 "비슷하다"로 보였지만 30회로 늘리자 RF 우세가 뚜렷해졌습니다 — 반복 횟수가 적으면 결론이 불안정하다는, 이 프로젝트에서 반복적으로 확인된 교훈이 여기서도 나타났습니다.

3차 검증 — 정답을 안 보고 고른 threshold(nested)로도 확인

위 결과의 threshold는 "정답(test)을 본 뒤 고른 값"이라 낙관적일 수 있습니다. 검증셋만 보고 threshold를 고르고 그 값을 전혀 보지 않은 test에 적용하는 정직한 방식(nested)으로 재검증했습니다.

	RF(정답을 본 최적값)	RF(nested, 정직한 방식)
threshold	0.035±0.006	평균 0.065±0.080
Sensitivity	0.684	0.691
Specificity	0.684	0.642
격차	0.027	0.061
ROC - AUC	0.729	0.726

nested 방식으로도 성능이 거의 유지됩니다(Sensitivity는 오히려 더 높음). threshold가 대부분 0.02~0.1 사이에 몰려 있어(일부 fold에서 0.3~0.48로 튀는 경우가 있긴 하나) NN보다 훨씬 안정적으로 재현 가능한 threshold를 찾을 수 있다는 뜻입니다.

최종 결론

RandomForest(RF)가 신경망(NN)보다 skin 자극성 예측에 더 적합합니다.
Sensitivity · Specificity · MCC · ROC-AUC 모두 RF가 같거나 더 높고, 최적 threshold도 fold마다 훨씬 일관되게 재현됩니다. 처음엔 "NN으로 통일"이라고 결론 냈었는데, 이는 고정 threshold 0.5라는 불공정한 비교 때문이었고, 공정하게(각자 최적점에서, 반복 충분히) 비교하자 RF가 더 낫다는 것으로 결론이 바뀌었습니다.

다음 단계로 skin production 코드(train.py/evaluate.py/checkpoint 저장 방식)를 RF 기반으로 전환할지 결정이 필요합니다 — 이는 큰 설계 변경이라 팀 확인 후 진행합니다.

근거 코드: skin irritation/rf_feature_compare/ (skin_compare.py, rf_vs_nn_head2head.py, rf_vs_nn_balanced.py) · 세팅/진행상황.md 2026 - 11 - 05 기록