Skin Irritation 예측 모델 — 확정 개요

COS팀 · 학술제 · 모델링 종료일 2026-11-09 · modeling/skin_rf/skin_rf_checkpoint.joblib

모델 상태: 확정(FINAL) — 이후 추가 모델링 없음

1. 한 줄 요약

NTP ICE skin 혼합물 자극성 자료(Draize in-vivo, EPA Classification)와 자체 보강 데이터를 합쳐 구축한 662개 제형을 성분 구조(RDKit descriptor)·농도가중평균(wmean)·농도비율(resolved_pct)로 벡터화하고, RandomForest(500 trees, nz20 feature 선택, group-aware 5-fold)로 EPA Category 1-3 (자극 있음) vs Category 4(무자극)를 이진분류하는 모델.

2. 데이터 파이프라인

단계	내용
원천 데이터	NTP ICE skin_irritation.xlsx(Data_invivo 시트, Draize 동물실험) 중 Mixture=="Mixture" & Endpoint=="EPA classification" 필터 → 1,799건 원시 레코드
제형 단위 집계	Formulation_ID 기준 그룹화, 성분 CASRN·함량%로 조성 재구성. 자체 보강 데이터(AUG_ 접두사, v2/v3/v4, 118건) 병합
구조 해결	성분 CASRN/SMILES를 RDKit descriptor(desc_*, 217종)·Morgan fingerprint(fp_w_*, 2048비트)·AromaticProportion에 매칭(casrn_descriptors_full.csv)
제형 벡터화	성분별 descriptor를 wmean(투입 함량 가중평균)으로 집계 → 2266차원. +resolved_pct(구조 해결된 성분이 차지하는 함량 비율, 1차원) 추가 → 총 2267차원
그룹 식별자	comp_group_id = 해결된 성분 CASRN:함량 조성 해시(제품명이 달라도 같은 조성이면 같은 그룹) — 637개 고유 그룹, train/test 분리 시 그룹 누수 방지
최종 표본	662개 제형 중 3건 제외(MIX306/MIX442/MIX506) → 659건 사용

3. 라벨 정의

EPA Classification Category 1(부식/불가역)~4(무자극) 중, production이 쓰는 라벨B 기준: Category 1·2·3 → 양성(자극 있음, 1) / Category 4만 → 음성(무자극, 0). 양성 122건 / 음성 540건(662건 기준). (참고: 비교실험용으로만 쓰인 라벨A는 Category 1·2만 양성 — production 체크포인트는 라벨B만 사용, `binary_label`≡`binary_label_B` 100% 일치 확인됨.)

4. 모델 사양

항목	값
알고리즘	RandomForestClassifier(n_estimators=500, class_weight="balanced")
집계방식	wmean(농도가중평균) — min/top/max 전부 비교 검토 후 최종 유지(§6 참고)
feature 선택	nz20: train(or trainval) 샘플 기준 nonzero 개수 20 미만인 컬럼 제거(fold-internal, test 정보 미사용)
CV 전략	StratifiedGroupKFold(groups=comp_group_id) — 동일 조성 제형이 train/test에 동시에 들어가지 않음
threshold 선택	배포 체크포인트: train/val/test 3분할 중 val에서만 balance-point(|Sens Spec| 최소) 선택, test는 참고용으로만 사용(공식 보고 수치 아님) — 처음부터 누수 없는 구조
체크포인트	modeling/skin_rf/skin_rf_checkpoint.joblib (2026-11-08 교체, 이후 재학습 불필요 확인)

5. 성능 (공식 수치 — 반복 group 5-fold, 20회)

production 조합(라벨B·RandomForest·wmean·+resolved_pct)의 공식 재검증 수치 (`skin irritation/skin_official_grid_recheck.csv`, 20회 반복 pooled):

지표	값	참고
MCC	0.264 ± 0.020	Matthews 상관계수, 0에 가까울수록 무작위
Sensitivity	0.668	실제 자극성 제형을 찾아내는 비율
Specificity	0.667	실제 무자극 제형을 맞히는 비율
Sens Spec 격차	0.009	균형잡힌 모델일수록 0에 가까움

지표	값	참고
ROC-AUC	0.718	
n	659건 (comp_group_id 637그룹)	

참고(배포 체크포인트 단일분할, 공식 수치 아님): n=134 테스트셋에서 Sens 0.594 / Spec 0.676 / 격차 0.083 / MCC 0.236 / ROC-AUC 0.713 — 위 공식 반복수치와 같은 범위, 재현성 확인됨.

6. 집계방식(wmean vs top/min/max) 결정 이력

- 8차례에 걸친 비교(날짜·필터·그룹버그수정·threshold방식이 바뀔 때마다)에서 1위가 min→top→max→wmean→max로 계속 바뀜 — 방법론에 매우 민감한 비교였음.
- 가장 엄밀한 확정비교(outer5×inner3 nested CV, 동일 649건, 사전등록 기준)에서는 max가 통계적으로 명확히 앞섬(20/20회, p<0.000001).
- 그럼에도 wmean 유지로 최종 결정 — max는 성분 농도를 전혀 반영하지 않는 구조(descriptor 컬럼별 독립 최댓값)라 극미량 성분이 예측을 좌우할 수 있고, EPA/GHS의 어떤 공식 혼합물 분류 원칙과도 대응되지 않음. wmean은 유일하게 EPA/GHS 농도가중 합산 원리와 대응되는 방식.
- 관련 산출물(비교 스크립트·결과 CSV)은 "검토했으나 채택 안 함"의 증거로 레포에 보존.

7. 2026-11-09 수정된 결함 (eye팀 역-감사 계기)

결함	수정 내용
predict.py 라벨 표시 극성 오류	양성을 "EPA I/II"로만 표시(III도 양성인데) → "I/II/III 상당" / "IV 상당"으로 수정
0% 농도 falsy 버그	amount_pct=0을 기본값 1%로 대체하던 버그 → None만 기본값, 범위밖 값은 오류 처리
comp_group_id 정규식 10배 오류	".5%"를 "5%"로 잘못 파싱 — 원자료 전체 스캔해 실제 영향 0건 확인(재학습 불필요)
검증 노트북 버그 2건	resolved_pct 미제외 KeyError + 구버전 라벨(A) 정답컬럼 사용 — 수정 후 결과 재확인

8. 외부 사례 비교 (탐색적, production 성능 주장 아님)

반려동물 벼룩/진드기 샴푸 5종의 공개 SDS로 탐색적 비교(`cosmetic_validation/`). 구조 해결 가능한 4건 기준, §7의 버그 수정 후 재실행 시 라벨 일치 4/4. 단 구조 해결률이 성분 1~4%뿐이고 n=4라 일반화 근거로 쓸 수 없음 — README 원칙대로 "화장품 전이학습/외부검증 성능"이 아니라 적용가능성 탐색 사례로만 취급.

9. 알려진 한계 (문서화됨, 미해결 — 팀 결정 필요 시 재검토)

- baseline(농도 미포함) 비교군의 일부 그룹(81그룹/272행)이 fold를 넘나드는 현상 — production(+농도) 조합에는 영향 없음, baseline 비교 수치만 실제보다 유리하게 나왔을 가능성.
- 비교·그리드 스크립트(설정 선택용)의 threshold가 평가용 OOF를 재사용하는 구조 — 상대순위는 비교적 안정적이나 절대수치는 낙관적일 수 있음. 배포 체크포인트 자체의 threshold는 이 문제와 무관(§4).
- 재현성: 스크립트 일부가 개인 절대경로에 의존, 증강 원자료(skin_irritation_최종후보.xlsx) 일부가 레포가 아닌 개인 OneDrive에만 존재.

10. 산출물 경로

모델: modeling/skin_rf/skin_rf_checkpoint.joblib, train.py, evaluate.py, predict.py
데이터: skin irritation/skin_vectorized.csv (662×2295)
공식 성능: skin irritation/skin_official_grid_recheck.csv
집계방식 결정 기록: 세팅/wmean_vs_max_*.pdf(4건, 2026-11-09)
진행 전체 이력: 세팅/진행상황.md