skin 트랙 핵심 이슈 보고서

팀 COS · NTP ICE 피부자극성 예측 모델 · 2026 - 11 - 05 정리

핵심 이슈: 양성 샘플이 너무 적다

Early Stopping, 하이퍼파라미터 튜닝, 모델 구조 개선, feature 차원축소, ChemBERTa 추가 사전학습까지 시도해본 결과, 모든 문제가 결국 하나의 원인으로 수렴합니다 — 자극성이 있다고 확인된 샘플(양성)이 극히 적다는 점입니다.

	skin	eye
전체 샘플 수	541건	547건
양성(자극성 있음)	30건 (약 5%)	98건 (약 18%)
feature 차원(축소 전)	2,266개	-

feature는 2,266개나 되는데, 모델이 "자극성이 있다"고 배울 수 있는 사례는 29개뿐입니다. eye(98건, 18%)와 비교해도 skin의 양성 비율이 훨씬 낮습니다.

이 문제가 실제로 어떻게 나타났나

1) 거의 즉시 과적합

Early Stopping 실험에서 확인된 사실입니다. 모델이 학습을 시작한 지 1~2 epoch(전체 데이터를 1~2번 본 시점) 만에 검증 성능이 더 나빠지기 시작합니다. 즉 모델이 일반적인 패턴을 배우는 대신 train 데이터 30건을 통째로 외워버리는 쪽으로 더 빨리 가버립니다.

2) 평가 자체가 불안정함(노이즈)

양성 샘플이 적으니 데이터를 어떻게 나누느냐(분할 시드)에 따라 결과가 크게 흔들립니다. 같은 설정을 한 번만 평가하면 MCC가 ±0.03~0.05 정도 운에 따라 달라집니다 — 실제로 한 번은 "개선됐다"고 판단했던 하이퍼파라미터 변경을, 10회 반복 평가로 다시 보니 "노이즈였고 오히려 손해였다"로 결론이 뒤집힌 적이 있습니다. 그래서 지금은 모든 설정 비교를 10회 이상 반복 평가의 평균값으로만 판단합니다.

3) ChemBERTa로 추가 사전학습을 해봐도 개선되지 않음

교수님이 제안하신 "화장품 성분 SMILES로 추가 사전학습 → 분자 벡터로 예측" 방식을 팀원이 실제로 구현해 테스트했습니다. 성분이 train/test에 겹치지 않는 더 엄격한 분할로 보면, 아래처럼 어떤 방법을 써도 skin은 거의 다 "우연보다 못한" 수준입니다.

모델	skin MCC	skin ROC-AUC	eye MCC	eye ROC-AUC
RDKit + fingerprint(기존)	- 0.035	0.374	0.097~0.102	0.58
ChemBERTa, 사전학습 전	- 0.074	0.382	0.086	0.60
ChemBERTa, 추가 사전학습 후	- 0.065	0.353	0.132	0.62

MCC가 음수라는 건 "무작위로 찍는 것보다도 못하다"는 뜻입니다. eye는 ChemBERTa 추가 사전학습으로 미세하게(0.086→0.132) 좋아졌지만, skin은 어떤 방법도 효과가 없었습니다. (이 평가는 화장품이 아니라 원래 NTP ICE 데이터 안에서 진행된 내부 검증입니다.)

지금까지의 대응과 현재 최종 성능

다음 세 가지를 적용해 최대한 개선을 시도했습니다 — 각각 group 5 - fold 반복 평가로 검증 후 채택.

- Early Stopping: 검증손실이 나빠지기 시작하는 시점에서 학습을 멈춰 과적합 방지
- 모델 구조 단순화: 은닉층 2개→1개, dropout 0.2→0.0 (데이터가 적을수록 단순한 모델이 유리)
- Feature 차원축소: 2,266개 중 거의 다 0인 컬럼 제거 → 약 440개로 축소

지표	값	해석
Sensitivity	0.60	실제 자극성 있는 것 중 60%를 잡아냄
Specificity	0.76	비자극군(EPA III · IV)으로 분류된 것 중 76%를 맞게 분류함
Sens - Spec 격차	0.16	두 값의 균형이 비교적 잡힌 편
MCC	0.19	전반적 판정 품질 — 우연보다는 낫지만 강하지 않음
ROC - AUC	0.73	순위화 능력은 쓸만한 수준

참고: EPA 피부 분류 III · IV는 "완전 무자극"이 아니라 각각 중등도 · 경미한 자극을 포함합니다. 이진 라벨에서 0으로 묶은 것은 "자극 없음"이 아니라 "I · II보다 심하지 않음"이라는 뜻입니다.

결론

MCC 0.19는 "모델을 더 잘 튜닝하면 해결되는 문제"가 아니라, 양성 샘플 30건이라는 데이터 자체의 한계로 보입니다. 지금까지 시도한 개선들은 전부 한계 안에서 쥐어짠 최선이고, 추가로 구조나 하이퍼파라미터를 더 건드려서 얻을 수 있는 이득은 점점 줄어드는 구간에 들어왔습니다.

이런 이유로 팀은 skin · eye 각각 자기 데이터에 맞는 최적 모델을 독립적으로 쓰기로 했고, 화장품으로의 전이학습은 수행하지 않기로 결정했습니다. skin 모델의 현재 역할은 "화장품 적용"이 아니라 "작은 표본 · 고차원 feature · 조기종료가 성능에 미치는 영향을 보여주는 내부 검증 및 발표 자료"입니다.

근거: 세팅/진행상황.md (2026 - 10 - 30~31 기록), skin_stage23_repeatedcv_revalidation.ipynb, pretraining/evaluation_summary.json