[Skin] wmean vs max — 팀원 교정 반영 및 최종 합의

COS팀 · 학술제 · 2026-11-09 · 대상: 팀원 "wmean_vs_max_쉽게_설명한_판단보고서"(da3f4d9 검토) + 기존 skin팀 집계방식_wmean_vs_max_채택논쟁_정리_20261109.pdf

1. 결론부터

팀원이 제출한 4가지 교정 지적을 레포 코드·데이터로 직접 재검증한 결과 전부 사실로 확인됨. 기존 skin팀 보고서(da3f4d9)의 "1위가 계속 바뀌었다" 서술 중 일부가 부정확하거나 과장돼 있었음을 인정하고, 팀원이 제시한 최종 판단과 문구를 그대로 채택함.

"현재 결과는 max에 유리한 탐색적 근거다. 교체를 확정할 공정한 비교가 아직 부족하므로 wmean을 잠정 유지한다."

피해야 할 표현(팀원 지적, 동의함): "wmean이 이미 더 안전하거나 우수하다고 검증됐다" / "다음 실험 한 번이면 영구 확정된다" — 둘 다 현재 증거 수준을 넘어서는 과장.

2. 팀원의 4가지 교정 지적 — 레포로 직접 재검증

#	팀원 지적	검증 방법	검증 결과
1	"wmean·top만 비교하다 max를 추가"한 것은 두 방식의 순위가 뒤집힌 사례가 아님	skin_official_grid_recheck.csv(32조건)에서 라벨B/RF/+conc의 wmean·top 값 직접 대조	확인함. wmean(0.264) > top(0.251)로 두 방식의 순위 자체는 안 바뀜. max가 새로 들어와 둘 다 제친 것뿐 — "뒤집힘" 서술은 과장이었음
2	과거 비교(10/6, 11/7 초반)는 0.5 고정 기준선이었지, "균형 임계값"이 아니었음	진행상황.md 2026-10-31/11-05 기록 직접 확인("threshold 0.5 유지 확정/재확인")	확인함. 균형(balance-point) threshold는 2026-11-07~08에 와서야 도입됨. 기존 보고서가 초기 비교 행에도 "균형"이라고 적은 것은 오기
3	nz20 필터 외에 트리 모델의 설정(class_weight)도 같이 바뀌어서, 필터 하나의 효과로 단정할 수 없음	eval_aggregation_method_comparison.py(6번) vs rf_et_aggregation_concentration_grid.py(7–8번) 소스코드 직접 대조	확인함. RandomForest의 class_weight가 "balanced_subsample"(6번) → "balanced"(7–8번)로도 바뀜 — nz20만의 순수효과로 볼 수 없음
4	보존된 15회 반복 결과에는 wmean·top만 있고 min/max는 없음 — max 우위의 재현 근거로 쓸 수 없음	skin_official_grid_recheck_15rep.csv 컬럼(method) 직접 확인	확인함. 15rep 파일은 method∈{wmean,top}뿐. max 결과(0.302)는 20회 1회만 존재, 15→20회 재현성 검증이 안 된 수치

네 지적 모두 소스 코드·CSV·진행상황 기록으로 직접 재현 가능했고 전부 사실과 일치함. skin팀 쪽에서 반박할 근거 없음 — 교정 그대로 받아들임.

3. 그래도 "max가 현재 유리하다"는 사실 자체는 바뀌지 않음

- 위 4가지는 전부 "왜 지금 바로 못 바꾸는가"의 근거를 보강하는 교정이지, "max가 안 좋다"는 반증이 아님.
- 가장 엄밀한 단일 비교(nz20+그룹버그수정+class_weight 통일, 20회 반복, 라벨B/RF/+농도)에서 max(MCC 0.302, 표본 649) > wmean(MCC 0.264, 표본 659)인 것은 여전히 사실.
- 다만 두 숫자가 서로 다른 표본(649 vs 659)과 한 번의 OOF 기반 임계값 선택(평가셋으로 기준선도 고르고 같은 평가셋으로 채점)에서 나왔다는 한계가 있어, "공정하게 비교해도 우세한지"는 아직 확인되지 않음.

4. 합의된 다음 실험 프로토콜 (팀원 제안, 채택)

단계	내용
① 동일 표본·동일 분할	wmean·max 둘 다 계산 가능한 동일 649건만 사용. 라벨B·RandomForest·농도피처 포함 고정.
② 임계값 분리	특성 선택·임계값 결정은 학습(연습) 폴드 안에서만 수행(outer 5-fold × inner 3-fold). 같은 조성 제형이 학습·평가 양쪽에 섞이지 않게 comp_group_id 기준 그룹 분리 유지. 두 방식에 동일 규칙 적용.
③ 전체 + 다성분 하위집단	전체표본 점수뿐 아니라 다성분 제형만의 하위집단 결과도 함께 비교(단일성분은 집계방식 차이가 수학적으로 사라지므로).
④ 사전 결정 기준	결과를 보기 전에 "바꿀 만큼의 개선" 기준(필요 MCC 개선폭, Sens/Spec 허용범위)을 미리 정함. 평균 차이만 단순 대조해 사후적으로 결론 내리지 않음.
⑤ 20회 반복의 의미 재정의	20회 반복은 "새 표본 20개"가 아니라 "같은 자료를 20번 다시 나눈 것" — 이번 결과도 "영구 확정"으로 표현하지 않음.

비교 결과	결정
max가 사전에 정한 개선 기준을 충족	max 전환 검토 — train.py/evaluate.py/predict.py 집계로직 재작성, 재학습, 체크포인트 교체
차이가 불확실하거나 개선 기준 미달	wmean 유지 — 현재 근거로는 변경할 이점이 충분하지 않음으로 기록하고 종료

5. 현재 상태

- production은 wmean 그대로 유지(코드 변경 없음). 위 프로토콜의 실제 실행(outer5×inner3 nested CV 스크립트 작성·실행)은 아직 안 함 — 이것이 유일하게 남은 다음 작업.
- 세팅/집계방식_wmean_vs_max_채택논쟁_정리_20261109.pdf(기존 skin팀 보고서)는 "1위가 계속 바뀌었다"는 서술이 §2의 교정 1·2·3을 반영하지 않은 상태로 남아있음 — 이 문서가 그 교정판 겸 최종 합의 기록.
- 세팅/진행상황.md가 다른 팀원 작업으로 dirty하여 이번 합의 내용은 아직 그 파일에 병합되지 않음(기존 병합 대기 항목에 합류).