[Skin] wmean vs max 확정 비교 결과 — nested CV

COS팀 · 학술제 · 2026-11-09 · 팀원 제안 프로토콜(outer5×inner3, 동일 649건, 사전등록 기준) 실제 실행 결과

1. 결론

사전에 정해둔 4개 판정 기준을 전부 충족 — "max 전환 검토" 판정. 20회 반복 전부(20/20)에서 max가 wmean을 앞섰고, 통계적으로도 우연이라고 보기 어려운 수준(p<0.000001). 다만 이 보고서는 "전환해도 되는지" 근거를 제공하는 것이지, 전환을 실행한 것은 아님 — 실제 production 반영은 팀 확인 후 별도로 진행.

2. 왜 이 비교가 "확정"에 가까운가

이전까지의 비교들은 두 가지 문제가 있었음(팀원 지적, 2026-11-09 교정 반영 보고서에서 확인됨): ① wmean은 659건, max는 649건으로 표본 자체가 달랐음 ② threshold를 고를 때 평가용 데이터를 그대로 재사용해(OOF 기반 동일 데이터로 기준선 선택+채점) 절대 수치가 낙관적으로 부풀었을 가능성. 이번 비교는 두 문제를 모두 제거함:

항목	이전 방식(32조건 공식 그리드)	이번 방식(nested CV 확정비교)
표본	wmean 659건 / max 649건(불일치)	두 방식 다 계산 가능한 동일 649건
threshold 선택	평가용 OOF로 선택 + 같은 OOF로 채점	inner 3-fold(학습용 내부)에서만 선택, outer 봉인된 test는 한 번도 관여 안 함
비교 단위	wmean·max를 서로 다른 분할로 각자 평가	같은 rep=같은 outer/inner 분할 공유 (쌍대응·paired 비교 가능)
판정 기준	결과를 본 뒤 "MCC가 더 높다"로 판단	결과를 보기 전에 ΔMCC·p-value·gap· 하위집단 일치 기준을 미리 고정

3. 사전 등록 기준 (결과를 보기 전 고정) → 결과 대조

기준	전체(649건)	다성분 하위집단(274건)	충족
ΔMCC(max wmean) > 0.02	+0.0564	+0.0958	충족
paired t-test p < 0.05	p < 0.000001 (t=9.92)	p < 0.000001 (t=11.06)	충족
gap(Sens-Spec 격차) 0.05 이상 악화 금지	-0.0095(오히려 개선)	-0.0164(오히려 개선)	충족
전체·다성분 방향 일치(모순 없음)	+ (양수)	+ (양수)	충족

4. 상세 수치 (20회 반복, pooled outer 예측 기준)

구분	wmean MCC	max MCC	wmean Sens/Spec	max Sens/Spec	wmean AUC	max AUC
전체(649건)	0.2457±0.029	0.3021±0.028	0.647 / 0.667	0.692 / 0.691	0.7151	0.7368
다성분(274건)	0.2269±0.035	0.3227±0.031	0.732 / 0.538	0.782 / 0.604	0.7188	0.7522

20회 반복 전부(20/20)에서 max의 MCC가 wmean보다 높았음(전체·다성분 둘 다) — ΔMCC 최솟값도 전체에서 +0.022, 다성분에서 +0.029로 전부 양수. Sens/Spec·AUC도 전부 max가 더 좋거나 동등 이상, 한쪽을 희생해서 다른 쪽이 좋아지는 트레이드오프가 아님.

5. 남은 한계 (과장 금지)

- 20회 반복은 "같은 649건을 20번 다시 나눈 것"이지 새 표본 20개가 아님 — "영구 확정"으로 표현하지 않음.
- RandomForest·라벨B·+resolved_pct 조합 1가지만 확정 비교함. ExtraTrees 등 다른 모델에도 동일하게 max가 유리한지는 이번 비교 범위 밖(참고: 32조건 그리드에서는 ExtraTrees도 같은 패턴을 보였음).
- max는 descriptor 컬럼별 독립 선택이라 화학적으로 실재하지 않는 조합("프랑켄슈타인 벡터")이 합성될 수 있다는 해석가능성 문제는 이번 비교로 해소되지 않음 — 성능과 별개의 고려사항.

6. 승인 시 진행할 작업 (아직 실행 안 함)

단계	내용
① feature 파이프라인	max 집계(descriptor 컬럼별 최댓값)를 평가용 임시계산이 아니라 skin_vectorized.csv에 준하는 영구 CSV로 생성
② 코드 재작성	modeling/skin_rf/train.py, evaluate.py, predict.py의 집계 로직을 wmean에서 max로 교체
③ 재학습	교체된 파이프라인으로 production 체크포인트 재학습
④ 체크포인트 교체	기존 skin_rf_checkpoint.joblib 백업 후 신규 체크포인트로 교체

단계	내용
⑤ 검증	cosmetic_validation 노트북 등 기존 검증 스크립트 재실행해 정상 동작 확인, 커밋

팀 확인 후 진행 여부 알려주면 바로 착수함. 산출물: `skin irritation/skin_wmean_vs_max_nested_cv.csv`(원시 결과), `skin irritation/rf_feature_compare/nested_cv_wmean_vs_max.py`(비교 스크립트, 사전등록 기준이 코드 docstring에 명시됨).