[Eye Irritation] 1주차 정리 & 2주차 준비

COS팀 · 학술제 · 2026-08-18

1. 1주차 한 일

① 데이터 분류 — 원본 3,028행을 시험단위/평가기준별로 분리

- 혼합물(완성 제형) 613개 — 본 연구의 학습 대상
- 순물질 EPA 192행 / GHS 179행(고유물질 173종) — 학습셋 미포함, 별도 보관
- in vitro(Vitrigel) 118종, Draize 원점수 118종 — 시험법이 달라 별도 보관
- 혼합물은 GHS Response가 전부 결측 → 라벨은 EPA Classification만 사용(skin과 동일 결정)

② 데이터 보완 및 정제

- (a) SMILES 결측 보충: 단일화합물 4종(Abamectin, Spinosad, Spinetoram, Emamectin benzoate)을 PubChem에서 확보 → 성분 행 24개 복구
- (b) 함량 커버리지: FIFRA는 활성성분만 공개 → 제외보다 변수로 활용하는 방향 검토 중(미결)
- (c) 동일조성 상충라벨 8쌍(16개) → 위험성 높은 쪽 8개만 유지, 8개 제외
- → 보고된 최종 학습셋: 제형 579개

③ eye 보강데이터 후보 4개 확인

- DRD_Barroso2017_extracted.xlsx(681행): 순물질 562종 GHS+동물반응개체수 — 발표자료 가치 높음, 학습셋 직접 사용 불가
- DRD_usable.csv(334행): 정제판, 우리 활성성분과 겹치는 건 20종뿐 — 성분 라벨 보강용
- ICE_Eye_Irritation_CAP.xlsx(1,996행): 제형 608개가 우리 613개의 부분집합 → 데이터 증가 없음, ID 매칭 금지(제형명 매칭)
- eye_invitro_vitrigel.csv(118행): 시험법 다름 → 학습셋에 섞지 말 것, lag_time 180초는 절단값(cutoff)

2. 2주차 들어가기 전 확인 필요

실제 eye_filtered.csv를 열어 재확인한 결과, 보고 수치와 파일 수치가 어긋납니다.

(1) "613 → 579" 숫자가 파일과 안 맞음

- 실제 eye_filtered.csv의 mixture 고유 formulation_id는 608개 — 보고된 613개와 5개 차이
- 8쌍 상충 제거(8개 제외)를 재계산해도 정확히 맞지만, 608-8=600이라 최종 보고치 579와는 21개 추가 차이
- → 613→608→579 각 단계에서 몇 건이 왜 빠졌는지 로그로 재추적 필요, 안 하면 이후 단계 전부 재작업 위험

(2) 조성 완전동일 그룹 30개(62개 제형) — skin보다 큼

- CASRN+비율까지 완전히 같은데 formulation_id만 다른 그룹이 30개 확인됨(skin은 11그룹/22건)
- skin과 동일 원칙(합치기/유지+split시 그룹단위 분리)으로 처리 필요, 규모가 더 커서 영향 큼

(3) CASRN 결측 있는 mixture 제형 8개 — skin의 "~-related" 패턴과 같은지 미확인

3. 팀 간(Skin↔Eye) 크로스체킹 항목

- 잔여/미확인 성분 처리 원칙 통일 — skin팀도 동일 유형 문제("~-related" 12건) 있음, 같은 규칙으로
- 중복조성 제형 처리 원칙 통일 — eye 30그룹(62건) vs skin 11그룹(22건), 같은 기준으로 결정
- 라벨 스케일 비교 — eye epa_class(1.0~4.0 실수) vs skin Response(1~4 정수), 이분류(1~2 vs 3~4) 매핑 함수를 공동으로 하나만 정의
- 스키마 스타일 차이 — eye는 가공된 snake_case+플래그 컬럼(has_casrn, needs_structure_lookup 등) 구조, skin은 원본 컬럼(PascalCase) 그대로 → ③단계 합칠 때 통일 방식 논의

4. 참고: 확인된 수치 요약

항목	값
원본 분류	혼합물 613개(보고) / 실제파일 mixture 608개
최종 학습셋(보고)	579개 — 파일 기준 재확인 필요
상충라벨 제외	8쌍(16개) 중 8개 제외
CASRN 결측(mixture)	8개 제형
단일성분 제형 비율	373/608 (약 61%)
조성중복 그룹	30그룹 / 62건

2주차 할 일 추천

순서	작업	비고
0.	613→608→579 격차 재추적 + 조성동일 30그룹 확인	벡터화 전 필수 선행
1.	0번 완료 후 "최종 N개" 재확정+근거 기록	
2.	CASRN결측 8건, skin과 같은 "~-related" 유형인지 파악	skin팀과 비교
3.	skin과 같은 원칙으로 중복조성 처리 결정(스키마 통일)	leakage 방지
4.	위 1~3 반영 후 CASRN 표기 통일(CAS매핑 확정)	
5.	formulation_id × casrn pivot table(벡터화)	원 계획대로
6.	단일성분 분리 — 단일성분 비율 373/608(약 61%)	원 계획대로
(여유시)	DRD_usable.csv 등 보강데이터 실사용 여부 결정	