[Skin Irritation] 1주차 정리 & 2주차 준비

COS팀 · 학술제 · 2026-08-18

1. 1주차 한 일

① 필터링 — skin_irritation.xlsx → skin_filtered.csv

- 기준: Mixture=="Mixture" & Endpoint=="EPA classification" → 1,799건, Formulation_ID 고유 544개
- Response는 "Category 1~4" 텍스트가 아니라 숫자 1~4(1=부식성/불가역손상 ~ 4=무자극 추정)
- 클래스 분포: 4=1,434 / 3=259 / 1=71 / 2=35 — 4가 약 80%, 극심한 클래스 불균형 → 3주차 SMOTE/class_weight 방향 사전 결정 필요

② 결측치 — CASRN 12건 (전체의 0.67%)

- 발생 Formulation 6개: MIX82, MIX380, MIX86, MIX78, MIX514, MIX382 (Dichlorvos/Captan/Atrazine 계열)
- (B 보고) 같은 Record_ID가 성분별로 여러 행으로 나뉘는 구조 때문 → 원본 내부 join으로 복구 가능하다고 판단

③ skin 보강데이터(XGB.xlsx, Kang2023) 실사용성 확인

- 545행×39컬럼, descriptor 34개 결측 0건 — descriptor 자체는 바로 사용 가능
- CASRN 5건이 엑셀에서 날짜로 자동변환됨, 중복 88행 중 43건 라벨 상충(예: Geraniol이 Cat2/Cat3 둘 다), Physical state 대소문자 불일치
- → 캐스팅+dedupe+정규화 스크립트 작성 전에는 사용 불가
- descriptor.pdf(34개 정의표)는 원문과 1:1 일치, 별도 정제 없이 바로 활용 가능

2. 2주차 들어가기 전 확인 필요

직접 데이터를 열어 재확인한 결과, 1주차 결론 중 2곳은 그대로 다음 단계로 넘기면 위험합니다.

(1) CASRN 12건 = "결측 복구"가 아니라 "정책 결정" 문제

- 12건 전부 Chemical_Name이 "Captan-related derivatives", "Dichlorvos-related compounds" 형태 — 활성성분의 잔여/불특정 부산물이라 원래 CAS가 없는 성분
- 같은 Record_ID의 다른 행(예: Captan 133-06-2)의 CAS를 그대로 붙이면 서로 다른 화학물질에 동일 CAS를 부여하는 오류가 됨 → "join으로 복구"는 틀린 접근
- 다행히 제형당 비중은 0.03%~6%로 작음 → (a)제외 (b)"unknown residue" 더미성분 포함 중 하나로 정책만 정하면 됨

(2) 조성 중복 11그룹(22건), 그중 1건 라벨 상충

- CASRN+비율이 완전히 동일한데 Formulation_ID만 다른 그룹이 11개 존재 — 이대로 벡터화하면 train/test 분리 시 같은 조성이 양쪽에 걸쳐 성능이 부풀려질 위험(data leakage)
- 11그룹 중 1그룹은 동일 조성인데 Response(라벨)까지 다름 — 원인 규명 필요

MIX433 처리방침 관련: Response 2/3/4 혼재 — 다수결/최고위험도/제외 중 선택, pivot에 라벨 join 전에 필요

3. 팀 간(Skin↔Eye) 크로스체킹 항목

- 잔여/미확인 성분 처리 원칙 통일 — eye팀도 동일 유형 문제(CASRN 결측 8건) 있음, 같은 규칙으로
- 중복조성 제형 처리 원칙 통일 — skin 11그룹(22건) vs eye 30그룹(62건), 같은 기준으로 결정
- 라벨 스케일 비교 — skin Response(1~4 정수) vs eye epa_class(1.0~4.0 실수), 이분류(1~2 vs 3~4) 매핑 함수를 공동으로 하나만 정의
- 스키마 스타일 차이 — skin은 원본 컬럼(PascalCase) 그대로, eye는 가공된 snake_case+플래그 컬럼 구조 → ③단계 합칠 때 통일 방식 논의

4. 참고: 확인된 수치 요약

항목	값
필터링 결과	1,799건 / Formulation_ID 544개
클래스 분포	4=1,434, 3=259, 1=71, 2=35
CASRN 결측	12건(0.67%) — 6개 Formulation
단일성분 제형 비율	334/544 (약 61%)
조성중복 그룹(라벨상충 포함)	11그룹 / 22건 (그중 1그룹 라벨 상충)

2주차 할 일 추천

순서	작업	비고
0.	CASRN 12건 정책 재확인 + 중복조성 11그룹 라벨상충 원인 확인	벡터화 전 필수 선행
1.	MIX433 처리방침 결정	3주차로 미루지 않기
2.	"~-related" 12건 제외 vs unknown 더미 포함 결정	팀 합의 필요
3.	11그룹 합치기 / 유지+split시 그룹단위 분리 결정	leakage 방지
4.	위 1~3 반영 후 CASRN 표기 통일(CAS매핑 확정)	
5.	Formulation_ID × CASRN pivot table(벡터화)	원 계획대로
6.	단일성분 A/B 분리 — 단일성분 비율 334/544(약 61%)	원 계획대로
(여유시)	XGB.xlsx 전처리 스크립트(CAS캐스팅+dedupe) 착수	급하지 않음